

# Claude Certified Architect — Foundations Certification

## مطالعہ گائیڈ (سرکاری امتحانی گائیڈ کی بنیاد پر)

### تعارف

سرٹیفیکیشن اس بات کی تصدیق کرتی ہے کہ ایک ماہر حقیقی Claude Certified Architect — Foundations Claude Code، Claude Agent SDK، Claude API، اور Model Context Protocol (MCP) — یعنی بنیادی علم کا جائزہ لیتا ہے — کے ساتھ پروڈکشن ایپلیکیشنز بنائی جاتی ہیں۔ Claude و بنیادی ٹیکنالوجیز جن سے

agentic systems امتحانی سوالات حقیقت پسندانہ صنعتی منظرناموں پر مبنی ہوتے ہیں: کسٹمر سپورٹ کے لیے، multi-agent research pipelines، ڈیزائن کرنا، Claude Code کو CI/CD میں ضم کرنا، developer productivity، structured data بنانا، اور غیر ساختہ دستاویزات سے tools نکالنا۔

### هدف امیدوار

کرتا ہے آپ ship کے ساتھ پروڈکشن ایپلیکیشنز ڈیزائن اور Claude کے جو solution architect مثالی امیدوار ایک کے پاس کم از کم 6 ماہ کا عملی تجربہ ہونا چاہیے:

- Claude Agent SDK** — multi-agent orchestration، subagents کو delegate کرنا، tool integration، lifecycle hooks
- Claude Code** — CLAUDE.md، MCP servers، Agent Skills، planning mode
- Model Context Protocol (MCP)** — backend integration کے لیے tools اور resources
- Prompt engineering** — JSON schemas، few-shot examples، data extraction templates
- Context windows** — لمبی دستاویزات کے ساتھ کام، multi-agent context passing
- CI/CD pipelines** — automated code review، test generation
- Escalation and reliability** — error handling، human-in-the-loop

### امتحانی فارمیٹ

| پیرامیٹر         | قدر                                      |
|------------------|------------------------------------------|
| سوال کی قسم      | Multiple choice (میں سے 1 درست 4)        |
| اسکورنگ          | 100–1000 scale، passing score <b>720</b> |
| Guessing penalty | نہیں (سوال کا جواب دیں!)                 |
| Scenarios        | 8 4 (randomly selected) میں سے           |

## امتحانى مواد: 5 ڈومينز

| وزن | ڈومین                                       |
|-----|---------------------------------------------|
| 27% | 1. Agent architecture and orchestration     |
| 18% | 2. Tool design and MCP integration          |
| 20% | 3. Claude Code configuration and workflows  |
| 20% | 4. Prompt engineering and structured output |
| 15% | 5. Context management and reliability       |

امتحان منظر نام

### Scenario 1: Customer Support Agent

account اور، returns، billing disputes استعمال کرتے ہوئے Claude Agent SDK بناتے ہیں جو آپ ایک agent MCP tools ( `get_customer`، `lookup_order`، `process_refund`، `escalate_to_human` ) سنبھالتا ہے، مناسب first-contact resolution + % استعمال کرتا ہے 80 دفعہ ساتھ۔

## Scenario 2: Claude Code Code Generation

code generation, refactoring, debugging, documentation اور custom slash commands کے ساتھ، آپ کو اسے integrate کرنا سیکھنا پڑے گا۔

### Scenario 3: Multi-Agent Research System

تیار کرنا، جاننا، reports کو مکمل citations سسٹم کو report generation اور synthesis tasks کو specialized subagents اور coordinator agent سونپنا

## Scenario 4: Developer Productivity Tools

□ agent engineers کو unfamiliar codebases explore کرنے، boilerplate code اور routine tasks automate □□□ میں مدد دیتا □□ Built-in tools (Read, Write, Bash, Grep, Glob) اور MCP servers استعمال □□□ کد □□□ جاز□□□ ہیں □□

## Scenario 5: Claude Code for Continuous Integration

Claude Code کو CI/CD pipeline میں ضم کریں تاکہ automated code reviews، test generation، pull request feedback اور Prompts حاصل کیے جائیں۔

## Scenario 6: Structured Data Extraction

کرتا ہے، validate کے ذریعے JSON schemas کو output، سسٹم غیر ساختہ دستاویزات سے معلومات نکالتا ہے اور کو درست طور پر سنبھالنا چاہیے۔ edge cases پر برقرار رکھتا ہے اسے high accuracy اور

## Scenario 7: Conversational AI Architecture Patterns

multi-turn conversational systems میں جن میں context window management، turns متعدد، memory strategies، tool design کے لیے execution محفوظ، کا برقرار رکھنا instructions میں اور مہم یا متضاد، user inputs کو سنبھالنا شامل ہے۔

## Scenario 8: Agentic AI Tools (ہماری مدد کریں — مواد موجود نہیں)

میں شامل نہیں ہے۔ guide نہ دی لیکن ابھی تک اس candidates کی اطلاع امتحان دینے والے scenario اس کریں share میں GitHub Issues کے سوالات دیکھیں، تو انہیں scenario کے اصل امتحان میں اس شامل کر سکیں۔ آپ کا تعاون۔ اس شخص کی مدد کرے گا جو امتحان کی تیاری کر coverage تاکہ مہم مکمل رہے۔

## سرکاری دستاویزات

| وسیلہ                                       | URL                                                                                                                                                       |
|---------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| Claude API — Messages                       | <a href="https://platform.claude.com/docs/en/api/messages">https://platform.claude.com/docs/en/api/messages</a>                                           |
| Claude API — Tool Use                       | <a href="https://platform.claude.com/docs/en/build-with-claude/tool-use">https://platform.claude.com/docs/en/build-with-claude/tool-use</a>               |
| Claude API — Message Batches                | <a href="https://platform.claude.com/docs/en/build-with-claude/message-batches">https://platform.claude.com/docs/en/build-with-claude/message-batches</a> |
| Claude Agent SDK — Overview                 | <a href="https://platform.claude.com/docs/en/agent-sdk/overview">https://platform.claude.com/docs/en/agent-sdk/overview</a>                               |
| Claude Agent SDK — Hooks                    | <a href="https://platform.claude.com/docs/en/agent-sdk/hooks">https://platform.claude.com/docs/en/agent-sdk/hooks</a>                                     |
| Claude Agent SDK — Subagents                | <a href="https://platform.claude.com/docs/en/agent-sdk/subagents">https://platform.claude.com/docs/en/agent-sdk/subagents</a>                             |
| Claude Agent SDK — Sessions                 | <a href="https://platform.claude.com/docs/en/agent-sdk/sessions">https://platform.claude.com/docs/en/agent-sdk/sessions</a>                               |
| Model Context Protocol (MCP)                | <a href="https://modelcontextprotocol.io/">https://modelcontextprotocol.io/</a>                                                                           |
| MCP — Tools                                 | <a href="https://modelcontextprotocol.io/docs/concepts/tools">https://modelcontextprotocol.io/docs/concepts/tools</a>                                     |
| MCP — Resources                             | <a href="https://modelcontextprotocol.io/docs/concepts/resources">https://modelcontextprotocol.io/docs/concepts/resources</a>                             |
| MCP — Servers                               | <a href="https://modelcontextprotocol.io/docs/concepts/servers">https://modelcontextprotocol.io/docs/concepts/servers</a>                                 |
| Claude Code — Documentation                 | <a href="https://code.claude.com/docs/en/overview">https://code.claude.com/docs/en/overview</a>                                                           |
| Claude Code — CLAUDE.md and Memory          | <a href="https://code.claude.com/docs/en/memory">https://code.claude.com/docs/en/memory</a>                                                               |
| Claude Code — Skills (incl. slash commands) | <a href="https://code.claude.com/docs/en/skills">https://code.claude.com/docs/en/skills</a>                                                               |

|                                               |                                                                                                                                                                                   |
|-----------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Claude Code — Hooks                           | <a href="https://code.claude.com/docs/en/hooks">https://code.claude.com/docs/en/hooks</a>                                                                                         |
| Claude Code — Sub-agents                      | <a href="https://code.claude.com/docs/en/sub-agents">https://code.claude.com/docs/en/sub-agents</a>                                                                               |
| Claude Code — MCP Integration                 | <a href="https://code.claude.com/docs/en/mcp">https://code.claude.com/docs/en/mcp</a>                                                                                             |
| Claude Code — GitHub Actions CI/CD            | <a href="https://code.claude.com/docs/en/github-actions">https://code.claude.com/docs/en/github-actions</a>                                                                       |
| Claude Code — GitLab CI/CD                    | <a href="https://code.claude.com/docs/en/gitlab-ci-cd">https://code.claude.com/docs/en/gitlab-ci-cd</a>                                                                           |
| Claude Code — Headless (non-interactive mode) | <a href="https://code.claude.com/docs/en/headless">https://code.claude.com/docs/en/headless</a>                                                                                   |
| Prompt Engineering Guide                      | <a href="https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview">https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview</a> |
| Extended Thinking                             | <a href="https://platform.claude.com/docs/en/build-with-claude/extended-thinking">https://platform.claude.com/docs/en/build-with-claude/extended-thinking</a>                     |
| Anthropic Cookbook (code examples)            | <a href="https://github.com/anthropics/anthropic-cookbook">https://github.com/anthropics/anthropic-cookbook</a>                                                                   |

## نظریاتی بنیادیں: حصہ ۱

یہ حصہ تمام نظریاتی احاطہ کرتا ہے جس کی آپ کو امتحان میں کامیابی کے لیے ضرورت ہے۔ مواد کو کے مطابق — اس سے آپ کے domains کے مطابق ترتیب دیا گیا ہے، نہ کہ امتحانی concepts ٹیکنالوجیز اور موضوع کی زیادہ گہری سمجھ پیدا کر سکتے ہیں۔

## کی بنیادیں Claude API — Model Interaction: باب 1

دستاویزات: [Messages API](#) | [Prompt Engineering](#)

### 1.1 API Request Structure

Claude API کی request کی ر Claude Messages API کی پیروی کرتا ہے request-response model ایک شامل ہوتا ہے:

```
{
  "model": "claude-sonnet-4-6",
  "max_tokens": 1024,
  "system": "You are a helpful assistant.",
  "messages": [
    {"role": "user", "content": "Hi!"},
    {"role": "assistant", "content": "Hello!"},
    {"role": "user", "content": "How are you?"}
  ],
  "tools": [...],
  "tool_choice": {"type": "auto"}
}
```

### □□ م فیلڈر:

- `model` — model selection ( `claude-opus-4-6` , `claude-sonnet-4-6` , `claude-haiku-4-5` )
- `max_tokens` — response □□ زیاد □□ زیاد کی تعداد tokens میں زیاد □□ زیاد
- `system` — system prompt (model □□ کی تعریف کرتا □□)
- `messages` — conversation history (history تسلسل برقرار رکھنے □□ لیں □□ آپ کو مکمل □□)
- `tools` — tools کی definitions دستیاب
- `tool_choice` — tool selection strategy

## 1.2 Message Roles

`messages` array □□ roles □□ استعمال کرتا □□:

- `user` — user messages
- `assistant` — model responses (history □□ شامل کیے □□ جاتے □□ میں history (بھیجتے □□ وقت شامل کیے □□ جاتے □□ میں history □□)
- `tool` — tool call results (role واضح طور پر set □□ میں کیا جاتا؛ □□ `tool_result` content block کی صورت □□) □□ میں ظاہر □□ ہوتا □□

□□ Model requests بھیجنے چاہیے □□ `conversation history` میں آپ کو مکمل API request انتہائی □□: □□ آزاد □□ ہوتا □□ call محفوظ □□ میں رکھتا □□ — □□ state درمیان

## 1.3 Response میں `stop_reason` Field

□□ generation □□ model شامل □□ ہوتا □□، جو بتاتا □□ □□ `stop_reason` میں Claude API response کیوں روکی

| Value           | Description                      | Action                                              |
|-----------------|----------------------------------|-----------------------------------------------------|
| "end_turn"      | Model □□ response کر لیا مکمل    | □□ کو دکھائیں user نتیجہ □□                         |
| "tool_use"      | Model tool call □□ کرنا چاہتا □□ | Tool execute result دیں کریں اور                    |
| "max_tokens"    | Token limit □□ ختم □□ ہو گئی     | Response truncated □□ ممکن □□ limit □□ بڑھانی پڑ □□ |
| "stop_sequence" | Stop sequence □□ مل گئی          | □□ handle □□ مطابق application logic اپنی           |

کو کنٹرول کرتے agent loop سب سے اہم ہیں — یہی "end\_turn" اور "tool\_use" میں Agentic systems ہیں۔

## 1.4 System Prompt

System prompt متعین کرتا ہے behavioral rules اور context جو instruction ایک خاص

- messages array الگ ہوتا؛ یہ system field کا حصہ نہیں ہوتا؛ بلکہ الگ array
- user messages پر فوقیت رکھتا ہے
- میں لاگو رہتا ہے conversation ہوتا ہے اور پوری load ایک بار
- کی تعریف کے لیے استعمال ہوتا ہے output format اور role, constraints,

پیدا کر سکتی ہے مثال کے طور پر tool associations غیر ارادی wording کی system prompt: امتحان کے لیے اہم کو ضرورت سے زیادہ get\_customer کو model کی تصدیق کریں "جیسی ہدایت customer پر،" ہمیشہ استعمال کرنے پر مجبور کر سکتی ہے، حتیٰ کے جب یہ ضروری نہ ہو

## 1.5 Context Window

Context window text (tokens) جسے اس میں process ایک وقت میں model کی کل مقدار ہے جسے شامل ہے:

- System prompt
- message history مکمل
- Tool definitions
- Tool results

مسائل context-window:

1. **Lost-in-the-middle effect:** models input سے اعتماد سے زیادہ موجود معلومات پر اختتام پر موجود معلومات کو زیادہ input سے اعتماد سے زیادہ models process کر سکتے ہیں۔ حل: اہم معلومات شروع یا آخر کے قریب miss کرتے ہیں، مگر درمیان کی تفصیلات رکھیں۔
2. **Tool results** واپس کر کے 40+ fields tool شامل کرتا ہے اگر output میں tool call context کا جمع ہونا: ہر Tool results کا بڑا حصہ ضائع ہو جاتا ہے context مگر صرف 5 اہم ہوں، تو
3. **Progressive summarization:** history compress کرتے وقت numeric values, percentages, اور dates اکثر گم ہو کر غیر واضح ہو جاتے ہیں ("تقریباً"، "کچھ"، "چند")

## 2 Tools اور tool\_use: باب

Tool Use: دستاویزات

## 2.1 tool\_use کیا

برا Model کی اجازت دیتا external functions call Claude جو mechanism ایک tool\_use result کرتا اور execute اس code بنانا؛ آپ کا structured tool call request میں چلاتا — و code راست واپس کرتا

## 2.2 Tool Definition

کیا جاتا define کے ذریعہ JSON schema ایک tool

```
{
  "name": "get_customer",
  "description": "Finds a customer by email or ID. Returns the customer profile, including name, email, order history, and account status. Use this tool BEFORE lookup_order to verify the customer's identity. Accepts an email (format: user@domain.com) or a numeric customer_id.",
  "input_schema": {
    "type": "object",
    "properties": {
      "email": {"type": "string", "description": "Customer email"},
      "customer_id": {"type": "integer", "description": "Numeric customer ID"}
    },
    "required": []
  }
}
```

کے انتہائی اہم ہلو Tool description:

- Description tool selection** کی بنیاد پر descriptions کو ان کی LLM tools mechanism کا بنیادی Minimal descriptions ("Customer information retrieve کرتا) اُن مواقع پر غلطیوں کا (کرتا) overlap کے دو سر کے tools باعث بنتی ہیں جب کرتے ہوں
- Description میں شامل کریں:**
  - کیا کرتا اور کیا واپس کرتا Tool
  - Input formats اور example values
  - Edge cases اور constraints
  - مقابلہ میں کب استعمال و tool similar alternatives
- کی analyze\_document اور analyze\_content سے بچیں اگر overlapping descriptions ایک جیسے یا انہیں خلط ملط کر دے گا model تقریباً ایک جیسی ہوں، تو descriptions
- Built-in tools** MCP tools: agents similar functionality والے built-in tools (Read, Grep) کو MCP tools — مضبوط بنائیں MCP tool descriptions پر ترجیح دے سکتے ہیں اس سے بچنے کے لیے concrete advantages, unique data, یا context جو built-in tools میں کر سکتے ہیں

## 2.3 tool\_choice Parameter

کیسے منتخب کرتا model tools کے کنٹرول کرتا tool\_choice

| Value                                                       | Behavior                                                      | کب استعمال کریں                                    |
|-------------------------------------------------------------|---------------------------------------------------------------|----------------------------------------------------|
| <code>{ "type": "auto" }</code>                             | Model کرنا tool call خود ط کرتا یا کرنا text یا میں جواب دینا | default زیادہ تر حالات میں                         |
| <code>{ "type": "any" }</code>                              | Model کرنا tool call کو لازماً کوئی                           | guaranteed جب آپ کو structured output چاہیں        |
| <code>{ "type": "tool", "name": "extract_metadata" }</code> | Model کرنا tool call کو لازماً ایک مخصوص tool کو              | forced first step / execution order جب آپ کو چاہیں |

ا: م منظر نامہ:

- `tool_choice: "any"` + multiple extraction tools → model منتخب کرتا ہے، مگر پھر بھی tool بہترین model ملنا structured output
- Forced selection → enrichment (مثلاً) کی ضمانت چاہیں action جب آپ کو کسی خاص پم ( `extract_metadata` )

## 2.4 Structured Output JSON Schemas

حاصل کرنے کا سب سے قابلِ structured output Claude استعمال کرنا `tool_use` کے ساتھ JSON schemas

اعتماد طریقہ کے:

- Syntax (trailing commas، غائب نہیں ہوتے braces) کی ضمانت دیتا ہے JSON کے اعتبار سے درست (ہوتے)
- (موجود ہوتے ہیں required fields) نافذ کرتا ہے structure مطلوبہ
- Semantic correctness (values) کی ضمانت نہیں دیتا

Schema design — بنیادی اصول:



```
{
  "type": "object",
  "properties": {
    "category": {
      "type": "string",
      "enum": ["bug", "feature", "docs", "unclear", "other"]
    },
    "category_detail": {
      "type": ["string", "null"],
      "description": "Details if category = 'other' or 'unclear'"
    },
    "severity": {
      "type": "string",
      "enum": ["critical", "high", "medium", "low"]
    },
    "confidence": {
      "type": "number",
      "minimum": 0,
      "maximum": 1
    },
    "optional_field": {
      "type": ["string", "null"],
      "description": "Null if the information was not found in the source"
    }
  },
  "required": ["category", "severity"]
}
```

**Schema design rules:**

1. **Required** □□ **optional:** □□ required fields کو صرف اُن □□ میں جن کی معلومات □□ ہمیشہ □□ دستیاب □□ ہوگی۔ Required fields model پر data کو values غائب □□ ہونے پر مجبور کر سکتی ہیں □□۔
2. **Nullable fields:** □□ ایسی معلومات کا لی □□ "type": ["string", "null"] طور پر استعمال کریں جو ممکنہ طور پر □□ بنائے value واپس کر سکتا □□ بجائے اس کا □□ وہ خود ساختہ null Model موجود نہ □□ ہوں □□۔
3. **Enums with "other"**: □□ predefined categories کے لیے □□ بچانے □□ سد □□ ہونے □□ کی معلومات ضائع □□ ہونے □□ سد □□ بچانے □□ کے لیے □□ "other" شامل کریں □□ detail string ایک + "other"۔
4. **Enum "unclear"**: □□ بار □□ میں پُر اعتماد نہ □□ ہو — ایماندار model category اُن صورتوں کا لی □□ جب □□ "unclear" سد □□ بہتر □□ category غلط □□۔


## 2.5 Syntax □ بمقابلہ Semantic Errors

| Error type | Example                                                | Mitigation                                                 |
|------------|--------------------------------------------------------|------------------------------------------------------------|
| Syntax     | Invalid JSON، field غلط type                           | JSON schema کے ساتھ tool_use (ختم کر دیتا) ( )             |
| Semantic   | Totals match نہیں کرتے، value field غلط، hallucination | Validation checks، feedback کے ساتھ retry، self-correction |



### 3.3 Hub-and-Spoke: Coordinator اور Subagents

Multi-agent architecture عموماً hub-and-spoke topology میں بنائی جاتی ہے:



Coordinator کی ذمہ داریاں:

- Task کو subtasks میں تقسیم کرنا
- (dynamic selection) درکار subagents میں سے کون سا طے کرنا
- کو سونپنا subagents کام
- کرنا validate نتائج جمع اور
- Errors اور retries handle کرنا
- تک پہنچانا user نتائج

الگ ہوتا context subagents کا: اصول

- Subagents conversation history کی coordinator خود بخود inherit نہیں کرتے
- میں واضح طور پر دینا ہوتا subagent prompt context تمام ضروری
- Subagents memory share کرتے درمیان
- (observability اور error control) کے ذریعے گزرتی coordinator communication تمام

### 3.4 Subagents کے لیے Task Tool بنانا

Subagents Task tool کے ذریعے spawn میں جاتے ہیں:

```
# Coordinator میں allowedTools کے "Task" ہونا چاہیے
coordinator_agent = AgentDefinition(
    allowed_tools=["Task", "get_customer"]
)
```

Explicit context passing لازمی ہے:

```
# Bad: subagent کے پاس context نہیں ہے
Task: "Analyze the document"

# Good: context prompt مکمل میں
Task: "Analyze the following document.
Document: [full document text]
Prior search results: [web search results]
Output format requirements: [schema]"
```

**Parallel spawning:** coordinator ایک response میں متعدد Task s call کر سکتا ہے — subagents parallel چلتے ہیں:

```
# Coordinator کے ایک response میں شامل ہے:
Task 1: "Search for articles about X"
Task 2: "Analyze document Y"
Task 3: "Search for articles about Z"
# تینوں ایک ساتھ چلتے ہیں
```

## 3.5 Agent SDK میں Hooks

Hooks agent lifecycle میں transformation اور interception پر points کے مخصوص

PostToolUse tool result کو model سے intercept تک پہنچانے کے لیے:

```
# MCP tools کے تاریخ کو normalize formats سے تاریخ کو مختلف:
@hook("PostToolUse")
def normalize_dates(tool_result):
    # Unix timestamp -> ISO 8601
    # "Mar 5, 2025" -> "2025-03-05"
    return normalized_result
```

Outgoing-call interception hook policy والے actions کو block کرنے کی خلاف ورزی کرنے والے:

```
# refunds block مثال: $500 سے اوپر
@hook("PreToolUse")
def enforce_refund_limit(tool_call):
    if tool_call.name == "process_refund" and tool_call.args.amount > 500:
        return redirect_to_escalation(tool_call)
```

Hooks اور prompt instructions میں فرق

| Attribute       | Hooks                                                     | Prompt instructions                              |
|-----------------|-----------------------------------------------------------|--------------------------------------------------|
| Guarantee       | Deterministic (100%)                                      | Probabilistic (>90%, 100% نہیں)                  |
| کب استعمال کریں | Critical business rules, financial operations, compliance | General preferences, recommendations, formatting |
| مثال            | Refunds > \$500 block کریں                                | "Try to solve before escalating"                 |

استعمال کریں hooks، انہیں prompts — کے مالی، قانونی، یا حفاظتی نتائج کے failure قاعدے: جب

## 4: Model Context Protocol (MCP)

دستاویزات: [MCP](#) | [Tools](#) | [Resources](#) | [Servers](#)

## 4.1 MCP کیا ہے

MCP (Model Context Protocol) Claude کو external systems سے جوڑتا ہے جو open protocol ایک ہے۔ MCP resource types define تین بنیادی کرتا ہے:

1. **Tools** — functions (agent actions) کے لیے (CRUD operations, API calls, command execution)
2. **Resources** — context کے لیے (documentation, database schemas, content catalogs)
3. **Prompts** — predefined prompt templates کے لیے tasks عام

## 4.2 MCP Servers

MCP server ایک process جو MCP protocol implement کرتا ہے اور tools/resources جب فراہم کرنا چاہے۔ آپ MCP server سے connect کر سکتے ہیں:

- وہ خود بخود tools تمام
- ایک ساتھ دستیاب ہوتے ہیں tools کے connected servers تمام
- انہیں کیسے استعمال کرے گا model طے کرتی ہیں کے Tool descriptions

## 4.3 MCP Servers کو Configure کرنا

Project configuration ( `.mcp.json` ) — team usage کے لیے:

```
{
  "mcpServers": {
    "github": {
      "command": "npx",
      "args": ["-y", "@modelcontextprotocol/server-github"],
      "env": {
        "GITHUB_TOKEN": "${GITHUB_TOKEN}"
      }
    },
    "jira": {
      "command": "npx",
      "args": ["-y", "mcp-server-jira"],
      "env": {
        "JIRA_TOKEN": "${JIRA_TOKEN}"
      }
    }
  }
}
```

اہم نکات:

- میں ہوتا ہے version control میں محفوظ ہوتا ہے اور `.mcp.json` project root
- Environment variables ( `${GITHUB_TOKEN}` ) secrets میں استعمال ہوتے ہیں — tokens خود commit نہیں کیے جاتے

- کھ لیکھ دستياب ٿوٽا contributors ٿي تمام project ٿي

**User configuration ( ~/ .claude.json )** — personal/experimental servers لیکھ:

- User لیکھ home directory ٿوٽا
- Version control لیکھ share لیکھ ذريعہ
- Personal experiments لیکھ موزون testing اور

**Servers کا انتخاب:**

- Standard integrations (Jira, GitHub, Slack) لیکھ موجود سدھ لیکھ پڻ لیکھ community MCP servers کو ترجيح ڏين
- کھ لیکھ بنائين unique, team-specific workflows صرف custom servers اپني

## 4.4 MCP ۾ isError Flag

کو بتاتا ٿي کھ agent استعمال ٿوٽا ٿي isError: true ۾ response آتا ٿي تو error ۾ MCP tool ۾ جب call fail ٿي ٿي

**Structured error (اچھا):**

```
{
  "isError": true,
  "content": {
    "errorCategory": "transient",
    "isRetryable": true,
    "message": "The service is temporarily unavailable. Timeout while calling the orders API.",
    "attempted_query": "order_id=12345",
    "partial_results": null
  }
}
```

**Generic error (anti-pattern):**

```
{
  "isError": true,
  "content": "Operation failed"
}
```

Generic error agent — کیا کوئی معلومات ڏين ڏين — ڪريڻ retry کو فيصلہ سازی کھ لیکھ کوئی معلومات ڏين ڏين — کیا Generic error agent ڪريڻ؟

## 4.5 MCP Resources

Resources لیکھ بغير طلب ڪر سگهيا actions حاصل ڪرڻ کھ لیکھ agent context ۾ جو ايسا data

- Content catalogs (hierarchical navigation, کی فہرست project tasks مثلاً تمام)

- Database schemas (data structure سمجھنے کے لیے)
- Documentation (API references, internal guides)
- Issue/task summaries

Resource کا فائدہ: agent کے لیے exploratory tool calls میں پڑتی کے سمجھنے کے لیے agent کا فائدہ: Resource کا فائدہ: map فوری Resource کیا ہے

## 5 اور Claude Code — Configuration Workflows

دستاویزات: [Claude Code](#) | [Memory / CLAUDE.md](#) | [Skills](#) | [MCP](#) | [Hooks](#) | [Sub-agents](#) | [GitHub Actions](#) | [Headless](#)

### 5.1 CLAUDE.md Hierarchy

hierarchy استعمال کرتا ہے اس کی تین سطحی Claude Code میں جو instruction file(s) و CLAUDE.md ہے:

1. User-level: ~/.claude/CLAUDE.md
  - پر لاگو user صرف اسی
  - نمونہ ہوتا ہے share کہ ذریعہ VCS
  - working style اور preferences ذاتی
2. Project-level: .claude/CLAUDE.md یا root CLAUDE.md
  - پر لاگو project contributors تمام
  - ہوتا ہے manage کہ ذریعہ VCS
  - Coding standards, testing standards, architectural decisions
3. Directory-level: subdirectories میں CLAUDE.md
  - کہ ساتھ کام ہو تو لاگو ہوتا ہے files کی directory جب اسی
  - conventions کہ اُس حصہ کہ مخصوص codebase

~/.claude/CLAUDE.md میں ملتی کیونکہ و project instructions کو team member عام غلطی: ایک نئے میں رکھی گئی تھیں (user-level) ~/.claude/CLAUDE.md (project-level) کے بجائے

### 5.2 @path Syntax (File Imports)

جو جاتی configuration modular کر سکتا ہے، جس سے refer کے ذریعہ @path کو files بیرونی CLAUDE.md ہے:

Coding standards @./standards/coding-style.md میں بیان کیے گئے ہیں  
 Test requirements @./standards/testing-requirements.md میں ہیں  
 Project overview @README.md اور dependencies @package.json میں ہیں

- (نہ) میں space کوئی) آئے file path کے فوراً بعد @
- Relative اور absolute دونوں paths supported ہیں
- Relative paths کے مطابق file اُس resolve کے میں جس میں import کے وئے ہیں
- Maximum import nesting depth 5 ہے

شامل ہوتی ہیں، standards میں صرف متعلقہ package کم ہوتی ہیں اور duplication اس سے

کرنے کے organize کے حساب سے topic کو rules کا متبادل ہے، جو monolithic CLAUDE.md .claude/rules/

لیہ استعمال ہوتا ہے:

```
.claude/rules/
  testing.md          -- testing conventions
  api-conventions.md  -- API conventions
  deployment.md       -- deployment rules
  react-patterns.md   -- React patterns
```

YAML frontmatter **کے** **ساتھ** **paths** **conditional loading:**

```
---
paths: ["src/api/**/*.json"]
---
```

استعمال کریں۔ explicit error handling کہ ساتھ async/await کہ لیے API files واپس کریں۔ endpoint standard response wrapper

```
---
paths: ["**/*.test.tsx", "**/*.test.ts"]
---
```

استعمال ہونہ چاہئیں۔ describe/it blocks میں Tests  
 ہمیں، hardcoding، استعمال کریں Data factories  
 استعمال کریں، test database - نہ کریں Database mock

۱۰. کس کا کام کرتا ہے؟



- کرتا match سہ pattern paths کر جو file edit ایسا Claude Code ہوتا ہے جب load صرف اس وقت Rule ہو
- نہیں ہیں rules load ہوتا ہے — غیر متعلقہ tokens اور context اس سہ
- Glob patterns کرنے دینے ہیں، چاہے conventions apply کے لحاظ سہ file type آپ کو میں codebase files (tests, migrations) پر
- (کے لیے بہت مفید tests) کے ہیں بھی ہوں

کے استعمال کریں directory-level CLAUDE.md بمقابلہ .claude/rules/ والے paths

- .claude/rules/ with paths — جب conventions کئی directories میں بکھری files (tests, migrations) پر لاگو ہوں
- Directory-level CLAUDE.md — جب conventions خاص کسی directory اور کے ہیں اور کے ہیں ضروری نہیں ہوں

## 5.4 Custom Slash Commands اور Skills

skills کو (.claude/commands/) custom commands میں Claude Code version نوٹ: موجود ہے  
 بناتے commands /name formats کر دیا گیا ہے دونوں unify کے ساتھ (.claude/skills/) supported اب بھی format کا ذکر کرتی ہے — و (.claude/commands/) ہیں امتحانی گائیڈ

Slash commands reusable prompt templates ہیں جو /name کے ذریعے invoke کے ہیں:

**.claude/commands/ format (legacy, supported):**

```
.claude/commands/
review.md      -- /review -- standard code review
test-gen.md    -- /test-gen -- test generation
```

**.claude/skills/ format (current):**

```
.claude/skills/
review/SKILL.md -- /review -- frontmatter configuration
test-gen/SKILL.md
```

**Project commands** (.claude/commands/ یا .claude/skills/):

- کرنے والے سب کے لیے دستیاب ہوتا ہے ہیں repo clone میں محفوظ ہوتا ہے ہیں اور VCS
- یقینی بناتے ہیں consistent workflows ٹیم میں

**User commands** (~/.claude/commands/ یا ~/.claude/skills/):

- نہیں ہیں ہوتا ہے share کے ذریعے VCS جو commands ذاتی
- کے لیے workflows انفرادی

## 5.5 Skills — .claude/skills/

Skills advanced commands ہیں جو SKILL.md frontmatter کے ذریعے configure کے ہیں:

```
---
context: fork
allowed-tools: ["Read", "Grep", "Glob"]
argument-hint: "Path to the directory to analyze"
---
```

کا تجزیہ کریں۔ code structure میں directory دی گئی  
report پر ایک architectural patterns اور Dependencies

#### Frontmatter parameters:

| Parameter                                   | Description                                                                                                         |
|---------------------------------------------|---------------------------------------------------------------------------------------------------------------------|
| <code>context:</code><br><code>fork</code>  | Verbose output main session کو pollute کرتا isolated subagent کو Skill                                              |
| <code>allowed-</code><br><code>tools</code> | نہیں کر skill files delete مثلاً — security) دستیاب ہوں گے tools یہ محدود کرتا کہ کون سے<br>(سکے گی اگر اجازت نہ ہو |
| <code>argument-</code><br><code>hint</code> | مانگنے کا اشارہ argument کو تو invoke کے بغیر skill parameters جب                                                   |

#### Skill `CLAUDE.md` کے استعمال کریں:

- Skill — task مخصوص — on-demand invocation (review, analysis, generation) کے لیے
- `CLAUDE.md` — general standards اور conventions ہمیشہ لوڈ ہونے والے

#### Personal skills ( `~/claude/skills/` ):

- متاثر نہ ہوں teammates مختلف ناموں سے بنائیں تاکہ personal variants اپنی

## 5.6 Planning Mode `Direct Execution` کے مقابلہ

#### Planning mode:

- Model نہایت changes کرتا؛ plan اور investigate صرف
- Codebase explore کے لیے Read, Grep, Glob استعمال کرتا
- کرتا user approve تیار کرتا جس implementation plan ایک
- safe exploration کے side effects بغیر

#### Planning mode کے استعمال کریں:

- changes (files درجنوں) بڑے
- Multiple plausible approaches (microservices: boundaries کیسے define ہوں؟)
- Architectural decisions (کیا framework کون سا؟ structure؟)
- Unfamiliar codebase (change کی سمجھنا ضروری ہے)
- Library migrations 45+ files کو متاثر کریں

#### Direct execution کے استعمال کریں:

- Single-file fixes ساتھ stack trace واضح
- شامل کرنا validation check ایک
- changes اچھی طرح سمجھ گئی، غیر مبہم

#### Combined approach:

1. Investigation اور design کے لیے planning mode
2. User plan approve کر
3. Approved plan implement کے لیے direct execution

#### Explore subagent — codebase explore کے لیے specialized subagent:

- Verbose output کو main context سے isolate کرنا
- واپس کرنا summary صرف
- روکنا Multi-phase tasks میں context-window exhaustion

## 5.7 /compact Command

`/compact` context compress کے لیے built-in command:

- میں جگہ خالی کرنا context window کو summarize کر کے history چھپی
- Long investigation sessions میں verbose tool output سے context بھر جائے
- Risk: exact numeric values, dates, اور specific details summarization میں گم ہو سکتے ہیں

## 5.8 /memory Command

`/memory` sessions memory manage کے لیے built-in command:

- `CLAUDE.md` file editing تاکہ notes, preferences, اور context جا سکیں
- Information sessions اور startup کے بارے میں برقرار رہتی ہے
- Project conventions, user preferences, frequently used commands, اور current work context محفوظ کر کے مفید
- دوبارہ سمجھانے کا متبادل instructions میں وہی session

## 5.9 Claude Code CLI for CI/CD

`-p` (یا `--print`) flag:

```
claude -p "Analyze this pull request for security issues"
```

- Non-interactive mode: prompt process کرنا، اور print پر stdout، exit کرنا
- User input کا انتظار نہیں کرتا
- CI/CD pipelines میں Claude کا واحد درست طریقہ

CI کے لیے structured output:

```
claude -p "Review this PR" --output-format json --json-schema
'{"type":"object",...}'
```

- `--output-format json` — output کو JSON میں دیتا ہے
- `--json-schema` — output کو schema کے مطابق validate کرتا ہے
- Result کو automatically inline PR comments میں لے کر دے دیتا ہے

**Session context isolation:** Claude session میں جس code generate کیا گیا ہے، اکثر review کیا گیا ہے، اور اپنی reasoning context (model کو بتاتی ہے) کو چھپا کر دیتا ہے۔ چھپا کر دینے سے challenge ساتھ رکھتا ہے اور اپنی فیصلوں کو (model کو بتاتی ہے) کو چھپا کر دیتا ہے۔ چھپا کر دینے سے challenge ساتھ رکھتا ہے اور اپنی فیصلوں کو (model کو بتاتی ہے) کو چھپا کر دیتا ہے۔

**Duplicate comments** review results context میں دہرائے گئے ہیں، پھر review کے بعد دوبارہ commits سے بچاؤ: Claude میں شامل کریں اور unresolved issues report کو صرف نئے یا Claude میں شامل کریں اور

## 5.10 Session Management اور `fork_session`

`--resume <session-name>` named session کو resume کرتا ہے:

```
claude --resume investigation-auth-bug
```

- saved context کے ساتھ conversation کو جاری رکھتا ہے
- Long investigations sessions مفید ہیں جو متعدد sessions پر پھیلی ہوئی ہیں
- Risk: tool results stale ہو سکتے ہیں جو files کے بعد session اگر پچھلی

`fork_session` shared context سے independent branch بناتا ہے:

```
Codebase investigation
|
fork_session
/      \
Approach A:  Approach B:
Redux       Context API
```

- forks branch point تک context inherit کرتے ہیں
- forks کے بعد وہ آزادانہ طور پر diverge اس کے بعد
- Approaches compare یا strategies test کرنے کے لیے مفید ہیں

**Resume** نئی session کے بجائے نئے

- Tool results stale (files) کو بدل چکی ہیں
- context degrade کافی وقت گزر چکا ہے اور
- Resume کے بجائے نئے session کا مختصر خلاصہ ہے: tool data پرانے، کیا جائے restart "..."

# باب 6: Prompt Engineering — Advanced Techniques

دستاویزات: [Prompt Engineering](#) | [Anthropic Cookbook](#)

## 6.1 Few-shot Prompting

Few-shot prompting input/output میں 2–4 prompt دکھانے کے لیے expected behavior کے طریقے جس میں شامل کیے جاتے ہیں examples

**Few-shot text descriptions** زیادہ مؤثر کیوں

- "وہ کو کئی طریقوں سے سمجھا جا سکتا ہے" precise کیسے زیادہ instruction مہم
- Example دکھانا decision logic اور expected format غیر مہم طور پر
- Model pattern (صرف examples) کرنا generalize پر cases کو نئے

**Few-shot examples** کی اقسام اور استعمال

1. Ambiguous scenarios کے لیے examples:

```
Request: "My order is broken"
Action: Call get_customer -> lookup_order -> check status.
Rationale: "broken" damaged item کو آپ ہو سکتا ہے؛ order details میں درکار
```

```
Request: "Get me a manager"
Action: escalate_to_human call کریں فوراً
Rationale: Customer مانگ رہا ہے خود حل کرنے کی کوشش نہ کریں human واضح طور پر
```

2. Output formatting کے لیے examples:

```
Finding example:
{
  "location": "src/auth/login.ts:42",
  "issue": "SQL injection in the username parameter",
  "severity": "critical",
  "suggested_fix": "Use a parameterized query"
}
```

3. Acceptable کے لیے problematic code کے لیے examples:

```
// Acceptable (flag کریں):
const items = data.filter(x => x.active);

// Problem (flag کریں):
const items = data.filter(x => x.active == true); // Use strict equality ===
```

4. Different document formats سے extraction کے لیے examples:

Document with inline citations:

"As shown in the study (Smith, 2023), the rate is 42%."

-> {"value": "42%", "source": "Smith, 2023", "type": "inline\_citation"}

Document with bibliography references:

"The rate is 42%. [1]"

-> {"value": "42%", "source": "reference\_1", "type": "bibliography"}

## 5. Informal measurements کے لیے examples:

Text: "about two handfuls of rice"

-> {"amount": "~100g", "original\_text": "two handfuls", "precision": "approximate"}

Text: "a pinch of salt"

-> {"amount": "~1g", "original\_text": "a pinch", "precision": "approximate"}

Few-shot purely rule-based instructions میں مؤثر کے جو non-standard measurement units اور informal خاص طور پر instructions کے لیے بہت متنوع ہوتی ہیں

**Prompts استعمال strict JSON schemas کے لیے structured output جب format normalization rules میں:** شامل کریں normalization rules میں prompt کریں

Normalization:

- Dates: ISO 8601 (YYYY-MM-DD); "yesterday" -> absolute date compute کریں ہمیشہ
- Currency: numeric amount + currency code; "five bucks" -> {"amount": 5, "currency": "USD"}
- Percentages: decimal fraction; "half" -> 0.5

وہ values inconsistent درست و مگر JSON syntactically کم ہوتے ہیں جہاں semantic errors اس سے

## 6.2 Explicit Criteria بمقابلہ Vague Instructions

**Bad (vague):**

Code comments کی accuracy چیک کریں

Conservative high-confidence findings report کریں - صرف

**Good (explicit criteria):**

Comment کو problematic میں اُس صورت میں flag کریں جب:

1. Comment کا actual code behavior سے CONTRADICT ہو
2. Comment کا حوالہ دہ variable یا function کسی غیر موجود
3. TODO/FIXME comment ایسے bug جو کسی category میں

Flag نہ کریں:

- کہ لحاظ سے پرانہ style جو صرف comments ایسے
- wording inaccuracies معمولی
- Missing comments (category یہ الگ)

Severity criteria examples کے ساتھ define کے:

CRITICAL: User کہ لیے runtime failure  
Example: Payment process وقت NullPointerException

HIGH: Security vulnerability  
Example: SQL injection, XSS, missing authorization checks

MEDIUM: Logic bug کہ بغیر فوری impact کہ  
Example: Wrong sorting, off-by-one error

LOW: Code quality  
Example: Duplication, کہ لیے data چھوٹہ suboptimal algorithm

## 6.3 Prompt Chaining

Prompt chaining میں توڑنا sequence کی focused steps کو ایک complex task

Step 1: auth.ts analyze کریں (صرف local issues)  
-> Output: auth.ts میں issues کی list

Step 2: database.ts analyze کریں (صرف local issues)  
-> Output: database.ts میں issues کی list

Step 3: Integration pass (cross-file dependencies)  
-> Output: module boundaries پر issues

یہ کیوں اہم:

- **Attention dilution** — جب files دیکھتا تو کچھ files ایک ساتھ ہوت سی model سد بچاتا — جب shallow commentary کر سکتا اور باقی پر
- یقینی بناتا کہ consistent analysis quality کہ لیے file ر
- Cross-file interactions کی اجازت دیتا کہ لیے الگ analysis

Prompt chaining کب استعمال کریں dynamic decomposition بمقابلہ:

- **Prompt chaining** — predictable, repeatable tasks (code review, file migrations)
- **Dynamic decomposition** — open-ended investigations کہ دوران واضح ہوتے subtasks execution جہاں ہیں

## 6.4 “Interview” Pattern

Solution implement Claude clarifying questions کہ پوچھتا:

Claude: "API کہ لیے caching implement کہ چند سوالات  
1. پسند کرتے ہیں؟ cache invalidation strategy میں سے کون سی event-based یا TTL آپ  
2. قابل قبول ہے؟ stale data ہو تو کیا cache unavailable اگر  
3. Caching per-user یا global؟ مونی چاہیے  
4. Cache کیا ہے؟ expected data volume کہ لیے

یہ کب مفید:

- Unfamiliar domain (fintech, healthcare, legal systems)
- Implications and tasks (cache strategies, failure modes)
- Viable approaches context جہاں بہترین انتخاب

## 6.5 Validation اور Retry-with-Feedback

جب extracted data validation fail کرے:

```
Step 1: Document سے data extract کریں
Step 2: Validate کریں (Pydantic, JSON Schema, business rules)
Step 3: retry کریں کہ ساتھ context ہو error اگر:
- Original document
- Previous (incorrect) extraction
- Specific error: "Field 'total' = 150, but sum(line_items) = 145. Re-check values."
```

کب مؤثر ہوگا Retry:

- Format errors (date غلط format میں)
- Structural errors (field جگہ غلط)
- Arithmetic inconsistencies (model چیک دوبارہ کر سکتا ہے)

کب مدد نہیں کریں گا Retry:

- Information source document ہی نہیں
- Required context external (data کسی اور document میں کیا گیا)

**Pydantic validation tool:** Pydantic Python library جو schema-based data validation کے لیے استعمال ہوتی ہے امتحان کے لیے اس کے نکات یہ ہیں:

- **Structural validation:** types, requiredness, enum constraints JSON کے بعد code میں جانچا جاتا ہے
  - **Semantic validation:** custom validators business logic enforce کرتے ہیں (sum of items equals total! start\_date < end\_date)
  - **Validate-retry loops:** Pydantic validation failure پر error message بنا کر Claude کو error context میں prompt ساتھ دوبارہ کریں
  - **JSON Schema generation:** Pydantic models سے JSON Schema generate کر سکتے ہیں tool\_use کے لیے
- فراہم کرتا ہے single source of truth میں، جو ایک

## 6.6 Self-correction

Internal contradictions detect کرنے کا pattern:



```
{
  "stated_total": "$150.00",
  "calculated_total": "$145.00",
  "conflict_detected": true,
  "line_items": [
    {"name": "Widget A", "price": 75.00},
    {"name": "Widget B", "price": 70.00}
  ]
}
```

آپ `conflict_detected` دونوں نکالتا ہے — اگر وہ مختلف ہوں تو Model stated value اور computed value کو discrepancy handle کرنے دیتا ہے

## 7 Message Batches API: باب 7

دستاویزات: [Message Batches](#)

### 7.1 Overview

کرنے دیتا ہے batches submit کے requests کے لیے asynchronous processing کو Message Batches API

| Attribute               | Value                                                                    |
|-------------------------|--------------------------------------------------------------------------|
| Savings                 | 50% کے مقابلے میں 50 synchronous calls                                   |
| Processing window       | 24 hours (latency SLA guarantee) زیادہ سے زیادہ                          |
| Multi-turn tool calling | Supported نہیں (یک request = ایک response)                               |
| Correlation             | request اور response کے لیے <code>custom_id</code> field کو جوڑنے کے لیے |

### 7.2 Batch API کے مقابلے Synchronous API میں استعمال کریں

| Task                          | API         | Why                                                 |
|-------------------------------|-------------|-----------------------------------------------------|
| Pre-merge PR check            | Synchronous | Developer 24 hours انتظار کر رہا ہے؛ قابل قبول نہیں |
| Overnight tech-debt report    | Batch       | savings % صبح تک چاہیے؛ Result 50                   |
| Weekly security audit         | Batch       | savings % فوری نہیں؛ 50                             |
| Interactive code review       | Synchronous | درکار کے response فوری                              |
| 10,000 documents process کرنا | Batch       | Bulk processing؛ savings میں                        |

## 7.3 custom\_id کا استعمال

```
{
  "custom_id": "doc-invoice-2024-001",
  "params": {
    "model": "claude-sonnet-4-6",
    "max_tokens": 1024,
    "messages": [{"role": "user", "content": "Extract data from: ..."}]
  }
}
```

custom\_id آپ کو یہ کرنے دیتا ہے:

- Result کو original document link سے
- Failure submit دوبارہ کی صورت میں صرف
- Successful documents process کو دوبارہ

## 7.4 Batch کو Failures میں Handle کرنا

1. 100 documents کا batch submit کریں
2. 95 succeed 5 fail (context limit exceeded) ہوں
3. Failures کو custom\_id سے identify کریں
4. Strategy (میں تقسیم کریں chunks کو long documents مثلاً) بدلیں
5. 5 failed documents submit کو دوبارہ صرف اُن

## 7.5 SLA Planning

تک لگ سکتے ہیں 24 hours کو Batch API چاہے اور result میں hours اگر آپ کو 30

- Submission window: 30 - 24 = **6 hours**
- Batches کو deadline 24 hours سے کم از کم
- Frequent submissions 4 hour windows میں تقسیم کریں

# 8: Task Decomposition Strategies

## 8.1 Fixed Pipelines (Prompt Chaining)

ہوتا ہے defined step سے:

Document -> Metadata extraction -> Data extraction -> Validation -> Enrichment -> Final output

کب استعمال کریں:

- Task structure predictable (reviews ایک template follow کریں)
- پلاٹ سڈ معلوم ہوں steps تمام
- چا پیڈ reproducibility اور stability آپ کو

## 8.2 Dynamic Adaptive Decomposition

Subtasks intermediate results پر بنیاد کی generate ہوتے ہیں:

1. "Legacy codebase کے لیے tests add کریں"
2. -> Glob, Grep کریں structure map پہلے
3. کہ ساتھ partial coverage کہ، 2 tests بغیر modules ملا: 3 ->
4. -> Prioritize: payments module شروع کریں (high risk)
5. دریافت ہوئی dependency پر external API: کام کہ دوران ->
6. -> Adapt: tests پہلے mock add کریں کہ لیے external API لکھنے سہ پہلے

کب استعمال کریں:

- Open-ended investigative tasks
- شروع میں معلوم نہ ہو scope جب مکمل
- پر منحصر ہوں results کہ step پچھلے step جب ر

## 8.3 Multi-pass Code Review

10+ files والی pull requests کے لیے:

```
Pass 1 (per-file): auth.ts analyze کریں -> local issues کی list
Pass 1 (per-file): database.ts analyze کریں -> local issues کی list
Pass 1 (per-file): routes.ts analyze کریں -> local issues کی list
...
Pass 2 (integration): files درمیان کہ relationships analyze کریں
-> Cross-file issues: inconsistent types, circular dependencies
```

14 files کی pass پر ایک کی خراب:

- Attention dilution: shallow کچھ کی، deep analysis کی files کچھ
- Inconsistent comments: approve دوسری میں، pattern flag میں ایک file
- Missed bugs: cognitive overload واضح سڈ errors کی وجہ سڈ

## 9 Escalation اور Human-in-the-Loop: باب 9

### 9.1 کریں Escalate کی طرف Human کب

Escalation triggers (rules واضح):

| Situation | Action |
|-----------|--------|
|-----------|--------|

|                                                 |                                                                     |
|-------------------------------------------------|---------------------------------------------------------------------|
| Customer "get me a manager" واضح طور پر کہتا ہے | کریں؛ حل کرنے کی کوشش نہ کریں escalate فوراً                        |
| Policy request کو cover نہ کرتی ہو              | Escalate policy جب competitor price matching مثلاً کریں (ہو)        |
| Agent پیش رفت نہ کر سکے                         | کریں escalate کے بعد attempts مناسب تعداد میں                       |
| Threshold financial operation سے اوپر           | Escalate کے ذریعے prompt enforce، کے ذریعے hook ترجیحاً کریں (نہیں) |
| Customer multiple matches تلاش کرتے وقت         | مانگیں؛ انداز نہ لگائیں identifiers مزید                            |

نہیں ہیں reliable trigger جو:

| Unreliable method                  | Why it fails                                            |
|------------------------------------|---------------------------------------------------------|
| Sentiment analysis                 | نہیں کرتا correlate سے Customer کا mood case complexity |
| Model self-rated confidence (1–10) | کمزور calibration غلط ہو سکتا ہے؛ Model confidently     |
| Automatic classifier               | موجود نہ ہو training data؛ ممکن Overengineering         |

## 9.2 Escalation Patterns

Immediate escalation:

Customer: "I want to speak to a manager"  
 Agent: [کرتا escalate\_to\_human call فوراً]  
 NOT: "I can help with your issue, let me..."

Resolve escalation: کی کوشش کے بعد

Customer: "My refrigerator broke two days after purchase"  
 Agent: [کرتا warranty replacement offer، چیک کرتا]  
 escalate -> مطمئن نہ ہو customer اگر

Nuanced escalation (acknowledge → resolve → reiteration پر escalate):

Customer: "This is outrageous, I'm very unhappy with the quality!"  
 Agent: [frustration acknowledge] "سمجھتا ہوں frustration میں آپ کی"  
 [resolution offer] "replacement یا refund ہو سکتا ہے"  
 Customer: "No, I want to talk to someone!"  
 Agent: [customer insist دوبارہ -> immediate escalation]

کریں escalate دیں، اور صرف اسی وقت concrete solution کریں، پھر emotion acknowledge بنیادی اصول: پہلے  
 manager (نہیں) کریں escalate کے پہلے اطلاع پر dissatisfaction کی خواہش دہرائیں human customer جب  
 (مانگندہ کے برابر نہیں ہیں)

Policy gap کے لیے escalation:

Customer: "Competitor X has this item 30% cheaper—give me a discount"  
Policy: کرتی ہے price adjustments cover پر site صرف اپنی  
Agent: [escalate – policy competitor price matching کو cover نہیں کرتی]

## 9.3 Structured Handoff Protocols

Escalation کو دینی چاہیے structured summary human agent پر:

```
{
  "customer_id": "CUST-12345",
  "customer_name": "Ivan Petrov",
  "issue_summary": "Refund request for a damaged item",
  "order_id": "ORD-67890",
  "root_cause": "Item arrived damaged; photos attached",
  "actions_taken": [
    "Verified customer via get_customer",
    "Confirmed order via lookup_order",
    "Offered a standard replacement – customer insists on a refund"
  ],
  "refund_amount": "$89.99",
  "recommended_action": "Approve a full refund",
  "escalation_reason": "Customer requested to speak with a manager"
}
```

Human operator کو full conversation transcript صرف یہ — وں کو summary تک رسائی نہیں دیتی — صرف یہ self-contained اس لیے مکمل اور

## 9.4 Confidence Calibration اور Human Oversight

Data extraction systems کے لیے:

1. **Field-level confidence scores:** model کے extracted field کے لیے confidence score نکالتا ہے
2. **Calibration:** labeled validation sets کے thresholds tune کریں استعمال کر کے
3. **Routing:**
  - High confidence + stable accuracy -> automated processing
  - Low confidence یا ambiguous sources -> human review

**Stratified random sampling:**

- High-confidence extractions کے sample audit بھی باقاعدگی سے کریں
- Aggregate 97% accuracy کے document type 40 کے errors کے چھپا سکتی ہے
- Accuracy کے overall کو صرف analyze کے حساب سے field اور document type کے ہیں

# Multi-agent Systems میں Error Handling: باب 10

## 10.1 Error Categories

| Category   | Examples                                     | Retryable           | Agent action                           |
|------------|----------------------------------------------|---------------------|----------------------------------------|
| Transient  | Timeout, 503, network failure                | Yes                 | Exponential backoff کے ساتھ retry      |
| Validation | Invalid input format, missing required field | No (input fix کریں) | Request modify اور retry کریں          |
| Business   | Policy violation, threshold exceeded         | No                  | پیش alternative کو سمجھائیں؛ User کریں |
| Permission | Access denied                                | No                  | Escalate کریں                          |

## 10.2 Error-handling Anti-patterns

| Anti-pattern                                | Problem                                                  | Correct approach                                           |
|---------------------------------------------|----------------------------------------------------------|------------------------------------------------------------|
| Generic status “search unavailable”         | Coordinator decide نہیں کر سکتا کہ کیسے recover کرنا ہے  | Error type, query, partial results, alternatives واپس کریں |
| Silent suppression (empty result = success) | Coordinator match سمجھتا ہے کہ کوئی failure ملا، حالانکہ | “no results” اور “search failure” میں فرق کریں             |
| Workflow پر پورا failure ایک کرنا abort     | ضائع ہو جاتا ہے partial results تمام                     | Partial results کے ساتھ جاری رکھیں؛ gaps annotate کریں     |
| Subagent میں infinite retries               | Latency اور resources کا ضیاع                            | Local recovery (1–2 retries)، پھر coordinator تک propagate |

## 10.3 Structured Subagent Error

```
{
  "status": "partial_failure",
  "failure_type": "timeout",
  "attempted_query": "AI impact on music industry 2024",
  "partial_results": [
    {"title": "AI Music Generation Report", "url": "...", "relevance": 0.8}
  ],
  "alternative_approaches": [
    "Try a narrower query: 'AI music composition tools'",
    "Use an alternative data source"
  ],
  "coverage_impact": "Not covered: AI impact on music production"
}
```

کو فیصلہ کرنا کہ آیا ضروری معلومات دیتا ہے coordinator

- Modified query ساتھ retry کریں؟
- Partial results استعمال کریں؟
- subagent کو delegate کسی اور کریں؟
- gap annotate کریں؟ بغیر جاری رکھیں اور section اس

## 10.4 Final Synthesis میں Coverage Annotations

**## Report: AI Impact on Creative Industries**

**### Visual Art (FULL COVERAGE)**

[research results]

**### Music (PARTIAL COVERAGE – search agent timeout)**

[partial results]

⚠️ Note: coverage search agent timeout سے محدود ہے اس کی section

**### Literature (FULL COVERAGE)**

[research results]

# Context میں Production Systems: باب 11

## Management

### کریں Extract میں Separate Block کو Facts 11.1

Conversations history کو (جو summarize کے دوران summarize ہو جاتی ہے) key facts کو extract میں structured block میں:

```
=== CASE FACTS (کیا جائے update آئے fact جب بھی نیا) ===
Customer ID: CUST-12345
Order ID: ORD-67890
Order Date: 2025-01-15
Order Amount: $89.99
Issue: Damaged item on delivery
Customer Request: Full refund
Status: Pending manager approval
===
```

کیوں نہ ہو؟ summarized کتنی ہی history میں شامل کریں، چاہے prompt میں block ہو۔

### کریں Trimming کو Tool Results 11.2

اگر `lookup_order` 40+ fields مگر current task میں صرف 5 درکار ہیں واپس کرتا ہے مگر

```
# PostToolUse hook: صرف relevant fields رکھیں
@hook("PostToolUse", tool="lookup_order")
def trim_order_fields(result):
    return {
        "order_id": result["order_id"],
        "status": result["status"],
        "total": result["total"],
        "items": result["items"],
        "return_eligible": result["return_eligible"]
    }
```

کم ہو تو noise بچتا ہے اور context اس سے

### Position-aware Input 11.3

Lost-in-the-middle effect کو critical information کو ذہن میں رکھتے ہوئے:



[KEY FINDINGS – اوپر]

3 critical vulnerabilities ملیں...

[DETAILED RESULTS – درمیان]

=== File auth.ts ===

...

=== File database.ts ===

...

[ACTION ITEMS – آخر میں]

Priority: merge auth.ts vulnerabilities fix کریں.

## 11.4 Scratchpad Files

Long investigations میں agent key findings scratchpad file میں لکھ سکتا ہے:

```
# investigation-scratchpad.md
## Key findings
- PaymentProcessor in src/payments/processor.ts inherits from BaseProcessor
- refund() تین places میں call ہوئی ہے: OrderController, AdminPanel, CronJob
- External PaymentGateway API limit: 100 req/min
- Migration #47 میں refund_reason (NOT NULL) add کیا گیا - 01-12-2024
```

scratchpad دوبارہ چلانے کے بجائے agent discovery (میں session یا نئی) کو جائے context degrade جب consult کر سکتا ہے

## 11.5 Context Subagents کو Delegate کرنا

Main agent: "payments module کی dependencies investigate کریں"

-> Subagent (Explore): 15 files read کرتا ہے، imports trace کرتا ہے

-> Returns: "Payments depends on AuthService, OrderModel, and the external PaymentGateway API"

Main agent: context 15 میں files ایک بجائے line کے رکھتا ہے

**Separate context layer:** Multi-agent systems میں subagent context budget — میں کام کرتا ہے — Coordinator ملتی ہے information کے لیے ضروری task اسے صرف اپنے کو context allocate کرتا ہے، اور global state store، کرتا ہے subagent outputs aggregate، کرتا ہے "context leakage" اس سے بھر دیتا ہے جو information کو ایسی agent window نہیں ہوتا، جہاں ایک "context leakage" اس سے دوسروں کے لیے غیر متعلق ہے

**Subagents کے constrained context budgets:**

- Minimal context: specific task + ضروری data
- Subagent کو raw data dumps کے بجائے structured results کی ہدایت دینے کے لیے
- اور کم distractions کا مطلب کم tools کریں — کم limit کو toolset کے subagent سے allowedTools context cost

## 11.6 Structured State Persistence (crash recovery لی کرنا)

کرنا export پر location ایک معلوم state اپنی agent ر:

```
// agent-state/web-search-agent.json
{
  "status": "completed",
  "queries_executed": ["AI music 2024", "AI music composition"],
  "results_count": 12,
  "key_findings": [...],
  "coverage": ["music composition", "music production"],
  "gaps": ["music distribution", "music licensing"]
}
```

Coordinator resume پر ایک manifest load کرنا:

```
// agent-state/manifest.json
{
  "web-search": "completed",
  "doc-analysis": "in_progress",
  "synthesis": "not_started"
}
```

## 12 کو محفوظ رکھنا Provenance: باب 12

### 12.1 Attribution Loss Problem

گم ہو سکتا ہے link "claim → source" کی جاتی ہیں، تو results summarize سے sources جب متعدد

Bad: "The AI music market is estimated at \$3.2B." (No source, no year.)

Good:

```
{
  "claim": "The AI music market is estimated at $3.2B.",
  "source_url": "https://example.com/report",
  "source_name": "Global AI Music Report 2024",
  "publication_date": "2024-06-15",
  "confidence": 0.9
}
```

### 12.2 Conflicting Data کو Handle کرنا

دیں values مختلف sources جب دو

```
{
  "claim": "Share of AI-generated music on streaming platforms",
  "values": [
    {
      "value": "12%",
      "source": "Spotify Annual Report 2024",
      "date": "2024-03",
      "methodology": "Automated classification"
    },
    {
      "value": "8%",
      "source": "Music Industry Association Survey",
      "date": "2024-07",
      "methodology": "Survey of 500 labels"
    }
  ],
  "conflict_detected": true,
  "possible_explanation": "Methodology اور time period فرق کا"
}
```

کو coordinator کے ساتھ محفوظ رکھیں اور attribution کو اندھا دھند منتخب نہ کریں۔ دونوں کو value کسی ایک فیصلہ کرنے دیں۔

## 12.3 Correct Interpretation کے لیے Dates شامل کریں

سمجھ لیا جا سکتا ہے contradiction کو temporal differences کے بغیر Dates:

Bad: "Source A says 10%, source B says 15%. Contradiction."

Good: "Source A (2023) says 10%, source B (2024) says 15%. Likely 5+ سال میں 1% growth."

## 12.4 Content Type کے مطابق Render کریں

میں نہ ٹھونسیں format کے چیز کو ایک کی:

- Financial data -> tables
- News اور analysis -> prose
- Technical findings -> structured lists
- Time series -> chronological ordering

## باب 13: Claude Code کے Built-in Tools

### 13.1 Tool Selection Reference

| Task                              | Tool         | Example                                                          |
|-----------------------------------|--------------|------------------------------------------------------------------|
| تلاش کرنا files کے نام/pattern    | <b>Glob</b>  | <code>**/*.test.tsx</code> , <code>src/components/**/*.ts</code> |
| File contents کے اندر search کرنا | <b>Grep</b>  | Function name, error message, import                             |
| File مکمل پڑھنا                   | <b>Read</b>  | Analysis کے لیے file load کرنا                                   |
| بنانا file نیا                    | <b>Write</b> | Scratch کے file create کرنا                                      |
| precise edit میں file موجود       | <b>Edit</b>  | Unique text match کے ذریعے specific snippet replace کرنا         |
| Shell command چلانا               | <b>Bash</b>  | git, npm, tests, build                                           |

### 13.2 Incremental Investigation Strategy

نہ: پڑھیں کے سمجھ بوجھ کو رفتہ رفتہ بنائیں files ایک ساتھ تمام

1. Grep: entry points تلاش کریں (function definition, export)
2. Read: پڑھیں files ملنے والی
3. Grep: usages تلاش کریں (import, calls)
4. Read: consumer files پڑھیں
5. کریں repeat نہ مل جائے picture جب تک مکمل

### 13.3 Fallback: Edit کے بجائے Read + Write

و: جائے fail کی وجہ سے Edit non-unique text match جب

1. Read — لوڈ کریں file content مکمل
2. Content کو programmatically modify کریں
3. Write — لکھ دیں updated version

## امتحانی ڈومین نوٹس: II حصہ

# 1 Agent Architecture اور Orchestration ڈومین 1 (27%)

## 1.1 Autonomous Task Execution لیجیٹو Agentic Loops Design کرنا

### Key knowledge:

- Agent loop lifecycle: Claude request بھیجیں، `stop_reason` ("tool\_use" بمقابلہ "end\_turn") چیک واپس کریں results کی لیجیٹو iteration کریں، اگلی tools execute کریں
- Tool results conversation history میں append کیے تاکہ model اگلا action کر سکے
- Model-driven decision making (Claude tool اگلا چنتا) بمقابلہ hard-coded decision trees

### Key skills:

- Flow control: جب `stop_reason = "tool_use"` تو loop جاری رکھیں اور `"end_turn"` پر رک جائیں
- Iterations درمیان tool results کو context میں append کرنا
- Anti-patterns سے بچنا: completion کی لیجیٹو assistant text parse کرنا، primary stopping mechanism کی استعمال کرنا arbitrary iteration limits پر

## 1.2 Multi-agent Systems (Coordinator–Subagent) Orchestrate کرنا

### Key knowledge:

- Hub-and-spoke architecture: coordinator تمام inter-agent communication، error handling، اور routing کا مالک ہوتا ہے
- Subagents isolated context میں کام کرتے ہیں — خود بخود coordinator کی history inherit نہیں کرتے
- Coordinator responsibilities: task decomposition، delegation، result aggregation، dynamic selection of subagents
- Coordinator کی overly narrow decomposition کا خطرہ

### Key skills:

- Research coverage کو subagents کی duplication درمیان تقسیم کریں تاکہ کم ہو
- Iterative refinement loops implement کریں (coordinator synthesis evaluate اور tasks re-route کریں)
- Observability تمام communication coordinator کے ذریعے route کریں

## کریا

### Key knowledge:

- Task tool subagents spawn: □□ کرتا coordinator □□ allowedTools میں "Task" □□ شامل ہونا چاہیے
- Subagent context prompt میں explicitly؛ □□ ہونا چاہیے؛ subagents parent context inherit □□ کرتے ہیں
- AgentDefinition configuration: descriptions, system prompts, tool constraints
- Alternatives explore □□ لپ □□ کرنا؛ fork\_session □□ ذریعہ session management

### Key skills:

- Previous agents کا full outputs subagent prompt میں شامل کریں
- Context pass کو metadata اور data کے الگ الگ structured formats میں کرنا وقت کے ساتھ ساتھ
- Coordinator turn میں متعدد tasks کے parallel subagents spawn کرنے کے ذریعے
- Coordinator prompts goals اور quality criteria کے طور پر، step-by-step instructions کے طور پر

## Workflows Implement کرنا

### Key knowledge:

- Workflow ordering اور **prompt guidance** (hooks, preconditions) کے **programmatic enforcement** کے لیے درمیان فرق
- **identity verification** (مثلاً مالی operations پر)، **prompts** کے **deterministic guarantees** درکار ہوں گے۔  
کافی نہیں ہوتے
- **structured handoff protocols** (customer ID, reason, recommended action) کے دوران **Escalation**

### Key skills:

- مکمل نہ ہوں steps کریں جب تک پبلو block کو downstream calls جو programmatic preconditions ایسا (کریں block `process_refund` واپس کرنے تک ID verified کے `get_customer` مثلاً)
- Multi-aspect customer requests الگ items کو کریں
- Human کو escalate وقت structured summaries produce کریں

## 1.5 Tool Calls Intercept اور Agent SDK Hooks

### Key knowledge:

- Hook patterns (مثلاً `PostToolUse`) tool results کو model consume نہ کرے۔ پھر وہ intercept کر کے refundس (مثلاً threshold اوپر) outgoing calls کو intercept کر کے compliance rules enforce کرے۔
- Hooks **deterministic guarantees** دیتی ہیں، جبکہ **probabilistic compliance** prompt instructions دیتی ہیں۔

## Key skills:

- `PostToolUse` hooks سے data formats normalize کریں (Unix timestamps, ISO 8601, numeric status codes)
- Policy-violating actions block کرنے کے لیے interception hooks اور escalation استعمال کریں اور redirect کریں
- منتخب کریں hooks کے بجائے prompts چاہیے۔ تو تو guaranteed compliance کو business rules جب

## 1.6 Complex Workflows کے لیے Task Decomposition Strategies

### Key knowledge:

- **Fixed pipelines** (prompt chaining) کے مقابلے میں **dynamic adaptive decomposition** کی بنیاد پر intermediate results
- Prompt chaining: sequential steps (پھر integration pass، analyze کو الگ الگ file)
- Adaptive investigation plans جو discovered information کی بنیاد پر subtasks generate کرتے ہیں

### Key skills:

- Predictable multi-aspect reviews کے لیے prompt chaining؛ open-ended investigations کے لیے dynamic decomposition
- Large code reviews کو per-file analysis + separate cross-file integration pass میں تقسیم کریں
- Open-ended tasks کو degrade ہونے والے prioritized plan پھر structure map کریں: پھر

## 1.7 Session State, Resuming, اور Forking

### Key knowledge:

- Named sessions continue کرنے کے لیے `--resume <session-name>`
- Shared context سے independent investigation branches بنانے کے لیے `fork_session`
- Resume کی اہمیت file changes کو agent کرتے وقت
- Structured summary کے ساتھ session، stale results کے ساتھ resuming زیادہ reliable سے زیادہ

### Key skills:

- Named investigation sessions continue کرنے کے لیے `--resume` استعمال کریں
- Approaches parallel compare کرنے کے لیے `fork_session` استعمال کریں
- Resuming (context ابھی current ہے) اور نئی session شروع کرنے (results stale ہیں) درمیان انتخاب کریں

## 5.10 fork\_session اور Session Management

`--resume <session-name>` named session کو resume کرتا ہے:

```
claude --resume investigation-auth-bug
```

- جاری رکھتا conversation کے ساتھ پچھلی saved context
- پر پھیلی ہوں ان کے لیے مفید sessions جو متعدد Long investigations
- Risk: tool results stale بدل چکی ہوں تو files کے بعد session اگر پچھلی

**fork\_session** shared context سے independent branch بنانا:

```
Codebase investigation
|
fork_session
/      \
Approach A:  Approach B:
Redux       Context API
```

- کرتے ہیں context inherit تک forks branch point دونوں
- کرتے ہیں diverge اس کے بعد وہ آزادانہ طور پر
- کرنے کے لیے مفید strategies test کرنے یا Approaches compare

**Resume** نئی session کے بجائے نئی:

- Tool results stale ہوں (files بدل چکی ہوں)
- وہ گیا context degrade کافی وقت گزر چکا ہو اور
- کرنے کے بجائے یہ بہتر ہے کہ "م نہ جو پایا اس کا مختصر خلاصہ یہ ہے": resume کے ساتھ tool data پرانے کیا جائے restart "... سے"

## 2 Tool Design اور MCP Integration (18%) ڈومین

### 2.1 Clear Descriptions کے ساتھ Tool Interfaces Design کرنا

#### Key knowledge:

- Tool descriptions minimal descriptions کرنا؛ LLM tools select میں جن سے mechanism و بنیادی unreliable selection دیتی
- Input formats, example queries, edge cases, اور applicability boundaries کی اہمیت شامل کرنے
- Ambiguous یا overlapping descriptions misrouting کا سبب بنتی ہیں
- System prompt wording tools کے associations کے ساتھ غیر ارادی بنا سکتی ہیں

#### Key skills:

- کریں distinguish سے واضح طور پر similar alternatives کو tool لکھیں جو descriptions ایسی
- Functional overlap کے لیے (مثلاً `analyze_content` -> `extract_web_results`) کریں tools rename ختم کرنے کے لیے
- واضح ہوں input/output contracts میں تقسیم کریں جن کے specialized tools کو General-purpose tools



## 2.2 MCP Tools کے لیے Structured Error Responses Implement کرنا

### Key knowledge:

- MCP tool responses میں `isError` flag
- Transient errors** (timeouts), **validation errors** (bad input), **business errors** (policy violations), اور **access/permission errors** کے درمیان فرق
- Generic errors ("Operation failed") میں recovery decisions روک دینے کے لیے
- Retryable اور non-retryable errors میں فرق

### Key skills:

- `errorCategory` (transient/validation/permission), `isRetryable` جیسی human-readable message اور `retryable: false` کے ساتھ user-facing explanations کے لیے واضح structured metadata واپس کریں
- Business-rule violations کے لیے واضح `retryable: false` استعمال کریں
- Transient failures کے لیے subagents میں local recovery کے لیے صرف وہ errors propagate کریں جو خود حل نہ کر سکیں
- Access failures (retry decision) اور valid empty results (no matches) میں فرق کریں

## 2.3 Agents میں Tools Allocation اور `tool_choice` Configure کرنا

### Key knowledge:

- کم کرتی tool selection reliability (مثلاً 18 کے بجائے 4-5) tools کے زیادہ
- Specialization کے لیے agents رکھنے والے tools سے باہر
- Scoped tool access: role-relevant tools + cross-role utilities محدود
- `tool_choice: "auto"`, `"any"` اور forced tool selection ( `{"type": "tool", "name": "..."}`  )

### Key skills:

- تک محدود رکھیں relevant tools صرف subagent کا toolset
- General tools کو constrained alternatives کے لیے بدلیں (مثلاً `fetch_url` -> `load_document` )
- `tool_choice: "any"` کے بجائے text answer کے لیے استعمال کریں تاکہ
- Specific tool force کے لیے execution order assured کریں تاکہ

## 2.4 MCP Servers اور Claude Code میں Agent Workflows کو Integrate کرنا

### Key knowledge:

- MCP server scope: user کے لیے experiments کے مقابلے میں project ( `.mcp.json` ) کے لیے ( `~/claude.json` )
- Secrets management کے لیے `.mcp.json` میں environment variable substitution (مثلاً `${GITHUB_TOKEN}` )

- available ہوتا ہے اور جاننے والے میں اور ایک ساتھ discover پر tools connection کے connected MCP servers تمام ہیں
- MCP resources بطور "content catalogs" (task summaries, database schemas) exploratory tool calls کم کرتے ہیں

### Key skills:

- Shared MCP servers کو project میں `.mcp.json` env-var-based tokens ساتھ configure کے کریں
- Personal/experimental servers کو `~/claude.json` میں رکھیں
- Standard integrations کے لیے community MCP servers کو custom servers پر ترجیح دیں

## 2.5 Built-in Tools (Read, Write, Edit, Bash, Grep, Glob) منتخب اور کرنا Apply

### Key knowledge:

- **Grep**: file contents کے اندر search (function names, error messages, imports)
- **Glob**: name/extension patterns کے تلاش کرنا files کے
- **Read/Write**: full-file operations؛ **Edit**: unique text matches کے ذریعے precise changes
- **Edit non-unique matches** کے لیے Read + Write جائیں تو fail کی وجہ سے

### Key skills:

- Content search کے لیے Grep اور pattern-based discovery کے لیے
- **Read** کے لیے flows trace پھر Grep کے لیے entry points: سمجھ بوجھ رفتہ رفتہ بنائیں
- Wrapper modules کے ذریعے function usage trace کریں

## 3 اور Claude Code Configuration: ڈومین Workflows (20%)

### 3.1 Hierarchy, Scope, اور Modular Organization کے ساتھ CLAUDE.md Configure کرنا

#### Key knowledge:

- CLAUDE.md hierarchy: user ( `~/claude/CLAUDE.md` ), project ( `.claude/CLAUDE.md` یا root `CLAUDE.md` ), اور directory-level (subdirectories میں CLAUDE.md)
- User-level settings اور user صرف ایک ہیں؛ VCS کے ذریعے share کے لیے اور لاگو ہوتے ہیں اور
- External files refer کے لیے `@path` syntax (مثلاً `@./standards/coding-style.md`) تاکہ CLAUDE.md modular بن سکے
- Monolithic CLAUDE.md بجائے `.claude/rules/` directory کے لیے topic-focused rule files کے

### Key skills:

- user-level اس لیے میں ملتیں کیونکہ وہ instructions کو team member (نہ) کریں Hierarchy issues diagnose (میں نہ) میں تھیں، project-level
- (مثلاً) @path کرنے کے لیے standards selectively include میں CLAUDE.md کے package کو استعمال کریں ( @./standards/testing.md )
- files (testing.md, api-conventions.md, deployment.md) .claude/rules/ کو متعدد CLAUDE.md بڑے میں تقسیم کریں

## 3.2 Custom Slash Commands اور Skills بنانا اور Configure کرنا

### Key knowledge:

- `~/.claude/commands/` بمقابلہ `(VCS کے ذریعے shared)` **Project commands** میں `~/.claude/commands/` **user commands** میں
- `~/.claude/skills/` میں SKILL.md frontmatter: `context: fork` , `allowed-tools` , `argument-hint`
- `context: fork` skill کو isolated subagent context سے تارک کرتا ہے تاکہ main session pollute نہ ہو
- Personal skill variants `~/.claude/skills/` میں رکھے جاسکتے ہیں

### Key skills:

- Project slash commands `.claude/commands/` پوری team میں رکھیں تاکہ پوری
- Verbose output `context: fork` استعمال کریں `skills isolate` والے `کے لیے`
- Skill `allowed-tools` محدود کرنے کے لیے `tools` کے استعمال کردہ
- Required parameters `argument-hint` مانگنے کے لیے

### 3.3 Conditional Convention Loading لیکھیں Path-specific Rules استعمال کرنا

### Key knowledge:

- `.claude/rules/` files میں YAML frontmatter `paths` تاکہ `glob patterns` شامل ہو سکتا ہے۔ `rules activate` ہوں
- `Path-scoped rules` `matching files edit` وقت `load` کریں، `tokens` اور `context`، `بچتے` ہیں
- `Glob-based path rules` `directory-level CLAUDE.md` میں جب `conventions` سے `بتر` ہو سکتے ہیں جب `tests` (مثلاً) `apply` میں `directories`

### Key skills:

- `paths: ["terraform/**/*"]` `.claude/rules/` files پر load matching files تاکہ صرف `files` کے ساتھ `paths` کے مطابق فائلوں کو تلاش کیا جاسکے۔
- Glob patterns ( `**/*.test.tsx` ) تاکہ `location` استعمال کریں تاکہ `file type` کے لحاظ سے `file type` کے مطابق فائلوں کو تلاش کیا جاسکے۔
- `path-specific` کے بجائے `directory-level CLAUDE.md` بھر میں پھیلی ہوئی `conventions codebase` جب کو ترجیح دیں



## Key skills:

- Interactive input پر hang لے کر لیجئے کہ CI میں Claude Code کو -p کے ساتھ چلائیں
- Structured results (مثلاً inline PR comments) کے لیے --output-format json + --json-schema استعمال کریں
- new/unfixed issues (صرف) شامل کریں review results کرتے وقت پچھلے run کے بعد دوبارہ commits نہ کریں
- Test generation quality کے لیے CLAUSE.md میں testing standards اور available fixtures document کریں
- style نہ ہو اور duplication میں شامل کریں تاکہ context کو existing test files کے وقت tests generate نہ کرے

## 4 Prompt Engineering اور Structured Output (20%)

### 4.1 Accuracy کے Prompts کے ساتھ Explicit Criteria، تر کرنے کے لیے Design کرنا

#### Key knowledge:

- Explicit criteria vague instructions میں زیادہ مؤثر ہوتے ہیں (مثلاً "flag comments only when they contradict code" بمقابلہ "check comment accuracy")
- "be more conservative" generic guidance concrete categorical criteria کے مؤثر ہیں
- False positives developer trust پر اثر انداز ہوتے ہیں: کچھ categories میں high false-positive rates درست کم کر دیتی ہیں trust پر بھی categories

#### Key skills:

- Review criteria define کرنا (bugs, security) اور ignore کرنا (minor style) report کرنا
- High false-positive rates والی categories طور پر disable عارضی طور پر
- explicit severity criteria define کے ساتھ code examples کے لیے level پر

### 4.2 Output Consistency کے Few-shot Prompting، تر کرنے کے لیے استعمال کرنا

#### Key knowledge:

- Few-shot examples consistently formatted, actionable output method پیدا کرنے کا سب سے مؤثر ہے
- Few-shot cases (tool selection, test coverage gaps) کو دکھا سکتا ہے
- Few-shot model کو patterns پر generalize کرنا، صرف مدد دینا، میں defaults کے لیے مدد دینا
- Few-shot extraction tasks میں hallucinations کو کم کر سکتا ہے

## Key skills:

- Ambiguous scenarios کے لیے rationale 4–2 کے ساتھ targeted examples دین
- Output format (location, issue, severity, suggested fix) کے ساتھ examples دکھانے والے
- میں فرق دکھائیں real issues اور acceptable code patterns دین جو examples ایسے
- دین examples کے extraction سے درست documents والے structures مختلف

## 4.3 Structured Output کے ساتھ JSON Schemas اور tool\_use کرنا Enforce

### Key knowledge:

- tool\_use with JSON Schemas schema-conformant output اور JSON syntax errors کی ضمانت دینے کا طریقہ قابل اعتماد کرنا کا سب سے
- tool\_choice: "any" واپس کر سکتا ہے؛ model text میں "any" منتخب کرتی ہے؛ forced selection specific tool؛
- Strict JSON Schemas syntax errors semantic errors ختم کرتی ہیں مگر (توٹا ہوا؛ totals) میں غلط fields values
- Schema design: required vs optional fields؛ enums کے ساتھ "other" + detail string extensibility کے لیے

### Key skills:

- JSON Schemas کے ساتھ extraction tools define کریں اور tool\_use results سے data parse کریں
- استعمال کریں tool\_choice: "any" یقینی بنانے کے لیے structured output کے ساتھ تو schemas متعدد
- Specific tool call force کریں: tool\_choice: {"type": "tool", "name": "extract\_metadata"}
- Source میں information کی صورت میں values fabricate نہ ہونے کی صورت میں optional/nullable رکھیں
- Extensible categorization کے لیے "unclear" اور "other" enum values + detail fields جیسے استعمال کریں

## 4.4 Extraction Quality کے لیے Validation, Retries, Feedback Loops Implement کرنا

### Key knowledge:

- Retry-with-error-feedback: correction guide کے لیے concrete validation errors میں retry prompt کرنے کے لیے شامل کریں
- فوائد ہونے والے retries میں موجود ہے؛ information source اگر
- Feedback loop design: finding کو trigger کرنے والا pattern (detected\_pattern) track کریں
- Semantic errors (totals reconcile نہ ہونے والے؛ syntax errors (جو tool\_use سے address نہ ہونے والے)

### Key skills:

- Original document, incorrect extraction, اور specific validation errors کے ساتھ follow-up prompts دین
- تو اس کی شناخت کریں (میں سے؛ external document صرف required info) کے فوائد؛ retry جب

- False positives analyze `detected_pattern` fields میں findings کرنے کے لیے
- Discrepancies detect `calculated_total` اور `stated_total` extract کرنے کے لیے self-correction design کریں

## 4.5 Efficient Batch Processing Strategies Design کرنا

### Key knowledge:

- Message Batches API: 50% savings, 24-hour processing window, latency SLA guarantee ہیں
- Batch processing non-blocking tasks (overnight reports, audits) اور blocking tasks کے لیے مناسب ہیں (pre-merge checks) نہیں
- Batch API single request میں multi-turn tool calling support کرتا ہے
- `custom_id` fields batch request/response correlate کرنے کے لیے اندر

### Key skills:

- Blocking checks synchronous API اور overnight/weekly workloads کے لیے Batch API استعمال کریں
- SLA needs مطابق batch submission cadence plan کریں (24-hour guarantee مثلاً 30 processing 4-hour windows کے ساتھ)
- Failed documents (identified by `custom_id`) submit صرف انہی کو دوبارہ کریں
- Large-scale processing کے ساتھ sample prompts iterate کریں

## 4.6 Multi-instance اور Multi-pass Review Architectures Design کرنا

### Key knowledge:

- Self-review limitations: model reasoning context اپنی فیصلوں کو اور اپنے challenge ساتھ رکھتا ہے اور امکان کم ہوتا ہے
- Independent review instances (generation context بغیر کے) subtle issues میں بہتر ہوتی ہیں
- Multi-pass review: per-file local analysis + cross-file integration pass attention dilution سے بچانا

### Key skills:

- Changes review second independent Claude instance کے بغیر generation context کرنے کے لیے کریں
- Multi-file reviews per-file passes + integration passes میں تقسیم کریں تاکہ cross-file dataflow analysis ہو سکے
- Self-rated confidence کے ساتھ verification passes کے reviews استعمال کر کے calibrated سے route طریقہ

## 5 Context Management اور Reliability (15%) ڈومین 5

### 5.1 Critical Information Conversation Context محفوظ رکھنا اور Manage کرنا

#### Key knowledge:

- Progressive summarization کے خطرات: numeric values, percentages, اور dates vague summaries میں بدل جاتے ہیں
- Lost-in-the-middle effect: models long inputs کے شروع اور آخر کو زیادہ reliable سے process طریقہ سے کر سکتے ہیں findings miss ہیں، لیکن درمیان کے
- Tool outputs relevance میں context کے مقابلہ میں disproportionately جمع ہو سکتے ہیں (40+ fields جب 5 fields کے درکار ہوں)
- Subsequent API requests میں full conversation history کی اہمیت

#### Key skills:

- Transactional facts کو summarized history سے باہر ایک persistent “case facts” block میں نکالیں
- Verbose tool outputs کو relevant fields تک trim کریں
- Key findings کو aggregated data کے شروع میں explicit section headings رکھیں
- Subagents کے structured outputs میں metadata (dates, sources) شامل کروائیں

### 5.2 Effective Escalation Patterns Design اور Ambiguity Resolve کرنا

#### Key knowledge:

- Suitable escalation triggers: human کی explicit request, policy gaps/exceptions, اور پانا
- Immediate escalation (explicit request) کے اندر attempt-to-resolve (agent scope) کے مقابلہ میں
- Sentiment analysis اور model confidence self-ratings case complexity کے unreliable proxies ہیں
- Multiple customer matches کے heuristic guessing کے بجائے additional identifiers چاہئیں

#### Key skills:

- System prompt میں explicit escalation criteria few-shot examples کے ساتھ دیں
- Human کی explicit request کو بغیر اضافی investigation کے فوراً execute کریں
- Escalate ہو تو silent یا ambiguous کے لیے specific request کسی policy جب
- Tool results میں multiple matches ہوں تو additional identifiers مانگیں



## 5.3 Multi-agent Systems میں Error Propagation Strategies کرنے

### Key knowledge:

- Structured error context (failure type, query, partial results, alternatives) coordinator کو smarter recovery دیتا ہے
- Access failures (timeouts retry decision میں) اور valid empty results (no matches) میں فرق کریں
- Generic error statuses ("search unavailable") coordinator سے valuable context چھپا دیتا ہے
- Silent suppression یا failure پر پورا workflow abort کرنا anti-patterns میں

### Key skills:

- Structured error context failure type, کیا گیا attempt, partial results, possible alternatives واپس کریں
- Access failures کو valid empty results الگ کریں
- Transient failures subagents کے لیے صرف local recovery میں non-recoverable errors partial results کے ساتھ propagate کریں
- Synthesis میں coverage annotate کیا اچھی طرح supported اور کے ان gaps میں

## 5.4 Large Codebases Investigate کرتے وقت Context Efficiently Manage کرنا

### Key knowledge:

- Long sessions میں context degradation: model unstable answers اور مخصوص classes دینے لگتا ہے
- Scratchpad files key findings کو context boundaries میں پار محفوظ رکھتے ہیں
- Subagents کو delegate سے verbose discovery output isolate ہو جاتی ہے
- Structured state persistence crash recovery ممکن بناتی ہے

### Key skills:

- Specific questions subagents spawn کے لیے high-level coordination main agent میں رکھیں
- Key findings scratchpad files کے لیے refer محفوظ رکھتے ہیں اور بعد میں
- Key findings summarize کے لیے subagents spawn کے phase اگلا ہے
- Long investigations دوران context usage کے لیے کم کرنے /compact استعمال کریں

## 5.5 Human Oversight اور Confidence Calibration کے ساتھ Workflows Design کرنا

### Key knowledge:

- Aggregate metrics (97% overall accuracy) specific document types یا fields پر کمزوری چھپا سکتا ہے
- Stratified random sampling high-confidence extractions میں error rates measure کرتا ہے

- Field-level confidence calibration labeled validation sets کے ذریعے
- Automation کے accuracy validate کے حساب سے field segment اور document type سے لے کر

### Key skills:

- New error patterns detect کے لیے stratified random sampling implement کریں
- Stable performance validate کے لیے field اور document type کے حساب سے accuracy analyze کریں
- Field-level confidence scores output کے review thresholds calibrate کریں اور labeled data کے ذریعے
- Low-confidence یا ambiguous-source extractions human review کی طرف route کریں

## 5.6 Multi-source Synthesis میں Provenance Preserve کرنا اور Uncertainty Handle کرنا

### Key knowledge:

- Summarization کے دوران attribution کے اگر claim → source mappings رکھو جاتی ہیں محفوظ نہ
- Aggregation کے دوران structured mappings کے برقرار رکھنی چاہئیں
- Conflicting statistics کو arbitrarily ایک value کے بجائے attribution منتخب کرنے کے ساتھ conflict annotate کے handle کریں
- Temporal differences کو contradiction کے لیے publication/collection dates سمجھنے سے بچنے کے لیے شامل کریں

### Key skills:

- Subagents کے “claim → source” mappings (URL, document name, quotes) output کروائیں
- Reports کو stable findings اور disputed ones میں الگ کریں structure
- Conflicting values کو annotations کے ساتھ محفوظ رکھیں اور reconciliation کے لیے coordinator کے
- Correct temporal interpretation کے لیے publication dates شامل کریں
- Content type مطابق render کریں: financial data tables، news prose، technical findings، structured lists میں

## Claude Certified Architect — Foundations Certification

### مطالعہ کے گائیڈ (سرکاری امتحانی گائیڈ کی بنیاد پر)

### تعارف

Claude Certified Architect — Foundations سرٹیفیکیشن اس بات کی تصدیق کرتی ہے کہ ایک ماہر Claude-based Claude Code، Claude Agent SDK، Claude API، اور Model Context Protocol (MCP) بنیادی ٹیکنالوجیز جن کے بنیادی علم کو جانچتا ہے — یعنی وہ trade-off حل بنانے کے وقت درست، یا امتحان کر سکتا ہے۔

اس کے ساتھ پروڈکشن ایپلیکیشنز تیار کی جاتی ہیں Claude کے

بنانا agentic systems امتحان کے سوالات حقیقی دنیا کے منظر ناموں پر مبنی ہوتے ہیں: کسٹمر سپورٹ کے لیے، multi-agent research pipelines، Claude Code کو CI/CD شامل کرنا، developer productivity، structured data بنانا، اور غیر ساختہ دستاویزات سے tools نکالنا

## هدف امیدوار

کرتا آپ ship کے ساتھ پروڈکشن ایپلیکیشنز ڈیزائن اور Claude کے جو solution architect مثالی امیدوار ایک کے پاس کم از کم 6 ماہ کا عملی تجربہ ہونا چاہیے:

- Claude Agent SDK** — multi-agent orchestration، subagents کو delegate کرنا، tool integration، lifecycle hooks
- Claude Code** — CLAUDE.md، MCP servers، Agent Skills، planning mode
- Model Context Protocol (MCP)** — backend integration کے لیے tools اور resources
- Prompt engineering** — JSON schemas، few-shot examples، data extraction templates
- Context windows** — لمبی دستاویزات، multi-agent context passing
- CI/CD pipelines** — automated code review، test generation
- Escalation and reliability** — error handling، human-in-the-loop

## امتحانی فارمیٹ

| پیرامیٹر         | قدر                                      |
|------------------|------------------------------------------|
| سوال کی قسم      | Multiple choice (میں سے 1 درست 4)        |
| اسکورنگ          | 100–1000 scale، passing score <b>720</b> |
| Guessing penalty | نہیں (سوال کا جواب دیں!)                 |
| Scenarios        | 8 4 میں سے (randomly selected)           |

## امتحانی مواد: 5 ڈومینز

| ڈومین                                       | وزن        |
|---------------------------------------------|------------|
| 1. Agent architecture and orchestration     | <b>27%</b> |
| 2. Tool design and MCP integration          | <b>18%</b> |
| 3. Claude Code configuration and workflows  | <b>20%</b> |
| 4. Prompt engineering and structured output | <b>20%</b> |
| 5. Context management and reliability       | <b>15%</b> |

# امتحانی منظرنامہ

## Scenario 1: Customer Support Agent

returns, billing disputes, account issues استعمال کرتے ہوئے Claude Agent SDK بناتے ہیں جو agent آپ ایک agent MCP tools (get\_customer, lookup\_order, process\_refund, escalate\_to\_human) سنبھالتا ہے۔ مناسب first-contact resolution % استعمال کرنا 80 دفعہ (escalation) کے ساتھ۔

## Scenario 2: Claude Code ساتھ Code Generation

code generation, refactoring, debugging, documentation آپ کو اسدے custom slash commands اور CLAUDE.md configuration کے استعمال کو سمجھنا planning mode کرنا، اور integrate

## Scenario 3: Multi-Agent Research System

tasks کو coordinator agent specialized subagents: web research, document analysis, synthesis, report generation اور citations سسٹم کو

## Scenario 4: Developer Productivity Tools

routine tasks بنانا، اور boilerplate code explore unfamiliar codebases کو agent engineers یں استعمال MCP servers اور Built-in tools (Read, Write, Bash, Grep, Glob) میں مدد دیتا ہے۔

## Scenario 5: Claude Code for Continuous Integration

pull اور automated code reviews, test generation, CI/CD pipeline کو Claude Code کم سے کم false positives ایسے بننے چاہئیں کہ Prompts حاصل ہو۔

## Scenario 6: Structured Data Extraction

JSON schemas کو output، سسٹم غیر ساختہ دستاویزات سے معلومات نکالتا ہے۔ درست طور پر سنبھالنے چاہئیں edge cases برقرار رکھتا ہے۔

## Scenario 7: Conversational AI Architecture Patterns

multi-turn conversational systems میں جن میں context window management، turns متعدد، memory strategies، execution محفوظ، tool design کے لیے، instructions میں اور مہم یا متضاد، user inputs کو سنبھالنا شامل ہے۔

## Scenario 8: Agentic AI Tools (ہماری مدد کریں — مواد موجود نہیں)

میں شامل نہیں دی لیکن ابھی تک اس candidates کی اطلاع امتحان دینے والے scenario اس میں share میں GitHub Issues کے سوالات دیکھیں، تو انہیں scenario اگر آپ نے اصل امتحان میں اس شامل کر سکیں آپ کا تعاون اس شخص کی مدد کرے گا جو امتحان کی تیاری کر coverage تاکہ ہم مکمل رہا

# نظریاتی بنیادیں: حصہ 1

یہ حصہ و بنیادی نظریہ بیان کرتا ہے جس کی آپ کو امتحان میں کامیابی کے لیے ضرورت ہے۔ مواد کو topic کے مطابق — اس کے domains کے مطابق ترتیب دیا گیا ہے، نہ کہ امتحانی concepts اور technologies کی گہری سمجھ بھنی۔

## کی بنیادیں Claude API — Model Interaction: باب 1

دستاویزات: [Messages API](#) | [Prompt Engineering](#)

### 1.1 API Request Structure

Claude API میں عموماً یہ Claude Messages API request پر کام کرتا ہے request-response model ایک request-response model میں شامل ہوتا ہے:

```
{
  "model": "claude-sonnet-4-6",
  "max_tokens": 1024,
  "system": "You are a helpful assistant.",
  "messages": [
    {"role": "user", "content": "Hi!"},
    {"role": "assistant", "content": "Hello!"},
    {"role": "user", "content": "How are you?"}
  ],
  "tools": [...],
  "tool_choice": {"type": "auto"}
}
```

م فیلڈز:

- `model` — model selection ( `claude-opus-4-6`, `claude-sonnet-4-6`, `claude-haiku-4-5` )
- `max_tokens` — response میں زیادہ سے زیادہ tokens
- `system` — system prompt (model کی تعریف)
- `messages` — conversation history (full history کی ضرورت ہے)
- `tools` — available tools کی definitions
- `tool_choice` — tool selection strategy

### 1.2 Message Roles

roles میں تین array: `messages`

- `user` — user messages
- `assistant` — model responses (history میں شامل ہوتے ہیں)

- `tool` — tool call results (عملاً `tool_result` content block)

محفوظ state کے درمیان Model requests بھیجیں conversation history میں مکمل API request م بات: ر آزاد ہوتی call نہیں رکھتا؛ ر

## 1.3 stop\_reason

Claude API response میں `stop_reason` کے جو بتاتا ہے کہ:

| Value           | Description              | Action                                 |
|-----------------|--------------------------|----------------------------------------|
| "end_turn"      | Model جواب مکمل کر لیا   | کو نتیجہ دکھائیں user                  |
| "tool_use"      | Model tool call چاہتا ہے | واپس دیں result چلائیں اور tool        |
| "max_tokens"    | Token limit ختم ہو گئی   | response truncated؛ limit میں          |
| "stop_sequence" | Stop sequence مل گئی     | کریں handle کے مطابق application logic |

کرتے loop control ہیں — یہی signals سب سے اہم "end\_turn" اور "tool\_use" میں Agentic systems ہیں

## 1.4 System Prompt

System prompt متعین کرتا ہے behavioral rules اور context کے جو instruction ایک خاص

- `messages` array الگ ہوتا؛ الگ `system` field کا حصہ نہیں ہوتا؛
- user messages پر فوقیت رکھتا ہے
- ہر پوری گفتگو میں لاگو رہتا ہے load ایک بار
- کی وضاحت کے لیے استعمال ہوتا ہے output format اور role, constraints,

کو غیر ارادی طور پر متاثر کر سکتی ہے مثال tool selection wording کی system prompt: امتحان کے لیے اہم ضرورت سے زیادہ `get_customer` کو model کی تصدیق کریں "جیسی ہدایت customer کے طور پر" ہمیشہ استعمال کرنے پر لے جا سکتی ہے

## 1.5 Context Window

Context window اس میں شامل process ایک وقت میں model کے جس (tokens) و کل متن

- System prompt
- message history مکمل
- Tool definitions
- Tool results

اہم مسائل:

1. **Lost-in-the-middle effect:** آغاز اور اختتام کی معلومات زیادہ مؤثر ہوتی ہیں، درمیان کی input لمبے details miss ہو سکتی ہیں حل: اہم معلومات شروع یا آخر میں رکھیں

2. **Tool results** واپس tool 40+ fields شامل کرتی ہیں اگر output میں tool call context کا جمع ہونا: ہر Tool results ضائع ہوتا ہے context کو مگر صرف 5 امیون تو
3. **Progressive summarization:** history compress کرنے پر numeric values, percentages, اور dates اکثر vague ہوتی ہیں

## 2 tool\_use اور Tools: باب 2

Tool Use: دستاویزات

### 2.1 tool\_use کیا ہے

براہ راست Model کو external functions call کرنے کے لیے Claude جس کے ذریعے mechanism tool\_use واپس کرتا ہے result کو execute اس کے لیے code بنانا ہے: آپ کا structured tool call نہیں چلتا — وہ code درست ہے

### 2.2 Tool Definition

tool JSON schema کے ذریعے define ہوتا ہے:

```
{
  "name": "get_customer",
  "description": "Finds a customer by email or ID. Returns the customer profile, including name, email, order history, and account status. Use this tool BEFORE lookup_order to verify the customer's identity. Accepts an email (format: user@domain.com) or a numeric customer_id.",
  "input_schema": {
    "type": "object",
    "properties": {
      "email": {"type": "string", "description": "Customer email"},
      "customer_id": {"type": "integer", "description": "Numeric customer ID"}
    },
    "required": []
  }
}
```

Tool description نکات:

1. Description کا سبب بنتی selection غلط Minimal descriptions mechanism کا بنیادی tool selection ہے
2. Description کا input format، کیا کرتا ہے، کیا واپس کرتا ہے tool میں شامل کریں
3. Overlapping descriptions سے بچیں
4. Built-in tools اور MCP tools overlap کو ہٹانے کے لیے MCP tool واضح بنائیں

## 2.3 tool\_choice

| Value                                                       | Behavior                         | کب استعمال کریں              |
|-------------------------------------------------------------|----------------------------------|------------------------------|
| <code>{ "type": "auto" }</code>                             | Model خود ط کرتا ہے              | default عام                  |
| <code>{ "type": "any" }</code>                              | Model tool call کو لازماً کرے گی | structured output جب چاہے    |
| <code>{ "type": "tool", "name": "extract_metadata" }</code> | Model tool call کو لازماً کرے گی | forced first step / order ہے |

## 2.4 JSON Schemas for Structured Output

reliable لینے کا سب سے structured output Claude استعمال کرنا `tool_use` کے ساتھ JSON schemas کی semantic correctness نافذ کرتا ہے، مگر required structure کم کرتا ہے اور syntax errors طریقہ سے یقیناً ضمانت نہیں دیتا

### اصول Design:

- رکھیں جو ہمیشہ ملنے چاہئیں required fields صرف وہ
- استعمال کریں nullable fields کے لیے missing data ممکنہ
- ضائع نہ ہو information شامل کریں تاکہ enum values جیسے "unclear" اور "other"

## 2.5 Syntax اور Semantic Errors

| Error type | Example                                 | Mitigation                                |
|------------|-----------------------------------------|-------------------------------------------|
| Syntax     | Invalid JSON, field type غلط            | JSON schema کے ساتھ <code>tool_use</code> |
| Semantic   | Totals match نہیں کرتے، value field غلط | Validation checks, feedback retry         |

# بنانا Claude Agent SDK — Agentic Systems: باب 3

دستاویزات: [Agent SDK](#) | [Hooks](#) | [Subagents](#) | [Sessions](#)

## 3.1 Agentic Loop

چلانا sequence کی actions صرف جواب نہیں دیتا، بلکہ Claude میں Agentic loop

- یہیجیں request کے ساتھ tools کو Claude
- Response لیں
- چیک کریں `stop_reason`:
  - "tool\_use" → tool چلائیں، result history پھر دوبارہ request میں ڈالیں،



- "end\_turn" → task کو دین user مکمل، نتیجہ task

مکمل ہونے تک دہرائیں۔ 4.

Text parsing یا arbitrary iteration دیکھیں کہ `stop_reason == "end_turn"` کہ لیں `signal: completion` درست قابل اعتماد نہیں ہیں۔


## 3.2 AgentDefinition

```
agent = AgentDefinition(
    name="customer_support",
    description="Handles customer requests for returns and order issues",
    system_prompt="You are a customer support agent...",
    allowed_tools=["get_customer", "lookup_order", "process_refund",
"escalate_to_human"],
)
```

اصول اپنائیں کہ Least privilege کہ `allowed_tools` اور، `system_prompt`، `description`، `name` م چیزیں:

## 3.3 Coordinator اور Subagents

استعمال کرتی ہیں hub-and-spoke topology اکثر Multi-agent systems:



Coordinator task کو توڑتا کہ، subagents نتائج جوڑتا کہ، کام سونپتا کہ، منتخب کرتا کہ، errors handle کرتا جواب پہنچانا کہ کہ final تک user کہ، اور

نہیں کرتے کہ inherit خود بخود parent history الگ ہوتا کہ؛ وہ کہ context کا subagents م اصول

## 3.4 Task Tool

Subagents `Task` tool کے ذریعہ spawn کہیں کہ Coordinator کہ `allowed_tools` میں `"Task"` ہونا چاہیے۔

context passing: صحیح

- Task: "Analyze the document" کافی نہیں
- Task: "Analyze this document. Full text: ... Output schema: ..." درست

Coordinator ایک response میں multiple Task s لے سکتا کہ، parallel subagents بھیج سکتا کہ

## 3.5 Hooks

Hooks lifecycle کے مخصوص points پر work کہیں کہ کرتے کہ

PostToolUse tool result کو model یں normalize کر سکتا ہے۔

```
@hook("PostToolUse")
def normalize_dates(tool_result):
    return normalized_result
```

**PreToolUse** policy violation block □□ کر سکتا

```
@hook("PreToolUse")
def enforce_refund_limit(tool_call):
    if tool_call.name == "process_refund" and tool_call.args.amount > 500:
        return redirect to escalation(tool call)
```

Critical business rules ہوتی ہیں۔ prompt instructions probabilistic ہوتے ہیں؛ hooks deterministic یاد رکھیں۔  
 rules ہوتے ہیں، hooks کے لئے۔

## باب 4: Model Context Protocol (MCP)

MCP | Tools | Resources | Servers: دستاویزات

## 4.1 MCP کا

resource سے جوڑتا ہے اس کے تین بنیادی Claude کو external systems سے جو open protocol ایک MCP types ہیں:

1. **Tools** — actions  $\square_{\text{J}}$   $\square_{\text{S}}$  functions
2. **Resources** — context data (documentation, schemas, catalogs)
3. **Prompts** — predefined task templates

## 4.2 MCP Servers

و جات tools discover و ن Connect کرتا expose tools/resources جو MCP server ایک process میں اور ک مطابق استعمال و ت میں descriptions میں اور

### 4.3 Configuration

### تیم کے لیے ( .mcp.json ) Project config

```
{
  "mcpServers": {
    "github": {
      "command": "npx",
      "args": ["-y", "@modelcontextprotocol/server-github"],
      "env": {"GITHUB_TOKEN": "${GITHUB_TOKEN}"}
    }
  }
}
```

User config سہ آتی ہے secrets environment variables میں ہوتی ہے؛ Project config version control (~/claude.json) personal/experimental servers کے لیے ہوتی ہے

## 4.4 isError

واپس کریں structured error کے بجائے Generic errors استعمال کریں `isError: true` میں MCP tool errors

```
{
  "isError": true,
  "content": {
    "errorCategory": "transient",
    "isRetryable": true,
    "message": "The service is temporarily unavailable."
  }
}
```

## 4.5 Resources

Resources کے پڑھ سکتا ہے action بغیر agent میں جو data و Resources: schemas, docs, content catalogs, summaries، exploratory tool calls میں کم کرتے ہیں

# 5 اور Claude Code — Configuration Workflows

دستاویزات: [Claude Code](#) | [Memory / CLAUDE.md](#) | [Skills](#) | [MCP](#) | [Hooks](#) | [Sub-agents](#) | [GitHub Actions](#) | [Headless](#)

## 5.1 CLAUDE.md Hierarchy

تین سطحوں پر ہو سکتا ہے CLAUDE.md

- **User-level:** `~/ .claude/CLAUDE.md` — پر لاگو user صرف اسی
- **Project-level:** `.claude/CLAUDE.md` یا `root` `CLAUDE.md` — کا لی team پوری
- **Directory-level:** subdirectories میں `CLAUDE.md` — folder conventions مخصوص

## 5.2 @path Syntax

CLAUDE.md میں @path کا external files refer کا تاکہ جا سکتا ہے میں تاکہ:

Coding standards `@./standards/coding-style.md` میں ہیں  
Test rules `@./standards/testing-requirements.md` میں ہیں

## 5.3 .claude/rules/

`.claude/rules/` rules کو topic کا لحاظ سے organize کا کرتا ہے اور `paths` کا ذریعہ conditional loading دیتا ہے:

```
---
paths: ["src/api/**/*"]
---
```

استعمال کریں explicit error handling اور async/await کہ لیں API files

## 5.4 Commands اور Skills

`.claude/commands/` project commands کا لی، جبکہ `~/ .claude/commands/` personal commands ملتی ہیں۔ skills کا ساتھ `.claude/skills/` میں کا لی

## 5.5 Skills اور context: fork

`context: fork` skill کو isolated context میں چلاتا ہے `allowed-tools` اور tool access کا `argument-hint` مانگیں required input کا

## 5.6 Planning Mode

Planning mode کا لی، multiple approaches، architectural تبدیلیوں، unfamiliar codebases کا لی، Direct execution اور واضح changes کا لی، بکتر کا

## 5.7 /compact اور /memory

`/compact` context compress کرتا ہے، اور `/memory` notes اور preferences میں مدد دیتا ہے



## 6.6 Self-correction

کریں discrepancy handle تو conflict دونوں نکال؛ Model stated value اور calculated value

## 7: Message Batches API

Message Batches: دستاویزات

### 7.1 Overview

Message Batches API asynchronous processing 50: % savings، up to 24 hours window، اور multi-turn tool calling supported، custom\_id requests اور responses link

### 7.2 کب استعمال کریں

Pre-merge checks اور interactive tasks، synchronous API، overnight reports اور bulk jobs، استعمال کریں Batch API

### 7.3 custom\_id

custom\_id result کو original document، جوڑ، failures identify اور صرف، failed items دوبار، submit میں مدد دیتا

## 8: Task Decomposition Strategies

### 8.1 Fixed Pipelines

Predictable tasks، fixed pipeline، Document → Extraction → Validation → Final output

### 8.2 Dynamic Decomposition

Open-ended tasks، subtasks intermediate results، کی بنیاد پر بنتے

### 8.3 Multi-pass Code Review

Large PRs، per-file analysis، cross-file integration pass، attention dilution، کم

## 9 Escalation اور Human-in-the-Loop: باب 9

### 9.1 Escalate کب کریں

Explicit user request, policy gaps, progress نہ ہونا, threshold سے اوپر financial action, یا ambiguous matching میں Sentiment analysis اور self-rated confidence unreliable ہیں۔ Escalate کی صورت میں

### 9.2 Escalation Patterns

human کو hand off نہ کرنا یا explicit insistence یا policy gap نہ کرنے کی کوشش کریں، پھر اگر resolve نہ ہو، مسئلہ حل کریں۔

### 9.3 Structured Handoff

human شامل کریں تاکہ recommended action اور actions taken, issue summary, customer ID پر Escalation operator کو مکمل context ملے۔

### 9.4 Confidence Calibration

Field-level confidence scores, calibration on labeled data, اور stratified sampling استعمال کریں۔

## 10 Error Handling میں Multi-agent Systems: باب 10

### 10.1 Error Categories

Transient errors retryable ہیں، validation errors input fix ہیں، مانگتی business errors policy-driven ہیں، اور permission errors generally escalate ہیں، اور

### 10.2 Anti-patterns

Generic “search unavailable” response, silent suppression, workflow abort یا پورا کرنا نقصان دہ۔ Structured errors واپس کریں۔

### 10.3 Structured Subagent Error

Structured error میں failure type, attempted query, partial results, alternative approaches, اور coverage شامل کریں۔

## 10.4 Final Synthesis میں Coverage

پارٹیاں، اور کچھ partially covered ہیں، کون سی sections fully covered میں واضح کریں کہ کون سی Report باقی ہیں۔ gaps

# 11 Context میں Production Systems: باب 11 Management

## 11.1 Facts Separate Block میں

Transactional facts کو persistent case facts block تاکہ summarization میں رکھیں تاکہ critical data کے باوجود زائد و اضافہ؛

## 11.2 Tool Results Trimming

PostToolUse hook رکھیں تاکہ relevant fields سے صرف

## 11.3 Position-aware Input

Important findings اور action items شروع میں اور lost-in-the-middle effect آخر میں رکھیں تاکہ

## 11.4 Scratchpad Files

Verbose findings scratchpad تاکہ long investigations میں لکھیں تاکہ محفوظ رہیں

## 11.5 Subagents کو Delegate کرنا

Exploration subagents میں اور main context میں صرف summary رکھیں

## 11.6 Structured State Persistence

ممکن ہے کہ crash recovery تاکہ export میں JSON file یا state manifest اپنی agent سے

# 12 Provenance رکھنا: باب 12 کو محفوظ رکھنا

## 12.1 Attribution Loss

Claim رکھیں تاکہ source URL، publication date، اور confidence کے ساتھ



## 12.2 Conflicting Data

کریں conflict flag ساتھ محفوظ رکھیں اور attribution دیں تو دونوں کو values مختلف sources اگر

## 12.3 Dates

دیکھیں publication dates سمجھنے کے لیے contradiction کو Temporal differences

## 12.4 Content Type کے مطابق Render

Financial data tables ، news prose ، میں ، technical findings structured lists اور time series ، میں دیکھائیں chronological order

# 13 Claude Code کے Built-in Tools : باب 13

## 13.1 Tool Selection Reference

| Task                      | Tool  | Example                      |
|---------------------------|-------|------------------------------|
| تلاش کرنا file کے pattern | Glob  | <code>**/*.test.tsx</code>   |
| file contents میں search  | Grep  | function name, error message |
| پڑھنا file                | Read  | analysis کے لیے              |
| بنانا file نیا            | Write | scratch کے                   |
| precise edit              | Edit  | unique text match            |
| shell command             | Bash  | git, npm, tests              |

## 13.2 Incremental Investigation

دیکھیں files consumer ، پھر usages ، پھر entry points ، پڑھیں ؛ کے files ایک ساتھ سب

## 13.3 Read + Write Fallback

کریں Write کریں ، پھر programmatically کریں ، تبدیلی Read کے تو Edit fail اگر

## امتحانی ڈومین نوٹس : II حصہ

## 1 ڈومین: Agent Architecture اور Orchestration (27%)

Agentic loops, coordinator–subagent architecture, Task ذریعہ spawning, hooks, escalation, اور multi-step workflows پر فوکس کریں

## 2 ڈومین: Tool Design اور MCP Integration (18%)

Tool descriptions, tool\_choice, JSON schema output, structured errors, MCP servers, resources, اور built-in tools کے فرق کو سمجھیں

## 3 ڈومین: Claude Code Configuration اور Workflows (20%)

CLAUDE.md hierarchy, .claude/rules/, commands, skills, planning mode, context: fork, اور CI/CD integration

## 4 ڈومین: Prompt Engineering اور Structured Output (20%)

Few-shot prompting, explicit criteria, prompt chaining, validation/retry loops, JSON schema enforcement, اور batch-friendly prompting پر توجہ دیں

## 5 ڈومین: Context Management اور Reliability (15%)

Summarization risks, lost-in-the-middle, trimming tool output, confidence calibration, escalation, اور provenance preservation یاد رکھیں

# Scenario 7: Conversational AI Architecture Patterns

## سوال 61

کرنے کے لیے preview سے پہلے اثرات کا execution میں tool remove\_team\_member صورتحال: آپ کے براہ راست agent سے معلوم ہوتا ہے کہ Production monitoring کے parameter dry\_run: boolean سے bypass کو preview step کو call کے ساتھ dry\_run=false کرتا ہے آپ کو یقینی بنانا ہے کہ user نے explicitly confirm سے preview سے پہلے ایک deletion کیا ہے

کونسی approach سب سے قابل اعتماد

- A) Server-side validation شامل کریں جو dry\_run=false سے 60 allow صرف اسی وقت کے ساتھ parameters میں seconds dry\_run=true call ہوئی ہے
- B) Tool کو configuration layer اور orchestration کی ضرورت کے طور پر confirmation کو user کی approval سے پہلے annotated tools کو calls forward

- C) Tool description agent شامل کریں جن میں few-shot examples اور instructions میں تفصیلی `dry_run=true` کو `call` سے `replace` کریں `preview_remove_member` impact details اور single-use confirmation token کو `preview` سے `bind`، درکار `token` کو `execute_remove_member` واپس کرتا ہے؛ `execute_remove_member` [درست] کرتا ہے

D) Token-binding approach سے `architecturally` `preview` ناممکن ہو جاتا ہے `execute tool` کو `literally` `execute` — `execute tool` جو صرف `token` `generate` `preview tool` `orchestration infrastructure` یا (A)، `timing heuristics` (C)، `LLM instructions` جو `approach` `code level` پر `constraint enforce` پر انحصار کے بجائے (B) کرتی ہے

## سوال 62

`search_catalog` tool 12% fail وقت `Production monitoring` کا آپ کا `search_catalog` سے معلوم ہوتا ہے کہ آپ کا `search_catalog` `query syntax errors` % پر کامیاب ہوتا ہے، اور `retry 4` میں جو `network timeouts` %: 8 `return` یکساں طریقہ سے `error types` کامیاب نہیں ہوتا ہے فی الحال دونوں `retries` میں ہوتی ہیں

کریں گے؟ `modify` کیسے `error handling` کی tool آپ

- A) System prompt میں few-shot examples شامل کریں جو `network errors` میں فرق کیسے کریں `syntax errors`
- B) `uniformly exponential backoff retry logic` apply کریں `errors` پر تمام
- C) Tool `network timeouts` کے اندر `automatic retry with backoff` implement کریں؛ `syntax errors` کے ساتھ فوری واپس کریں [درست] `parameter validation details`
- D) `retryable` boolean flag اور `error type details` کو `errors` تمام

C) Tool level پر `transient errors` کے لیے `retries` handle کرنا صحیح `abstraction boundary` — tool `error type` پر `agent` کر سکتا ہے بغیر `deterministic retry logic` کے بارے میں یقینی علم اور `Uniform backoff` (B) `syntax errors` `prompt instructions` (A) follow `interpret` (D) `flag` انحصار کے `errors` پر وقت ضائع کرتا ہے جو کبھی کامیاب نہیں ہوتے

## سوال 63

بہت کم "اور `risk tolerance` نہ `user`، میں `turns` کی گفتگو کے کئی `Investment strategy` `returns maximize` پھر "میں اپنے `invest` کرنا چاہتا ہوں؟" اب وہ پوچھتا ہے: "مجھے کس چیز میں `returns maximize` پھر "میں اپنے

سے `priority` کی اصل `recommendation user` سب سے بہتر طریقہ سے یقینی بنانا ہے کہ `approach` کونسا `مآنگ` ہے؟

- A) پوچھیں کہ کونسی چیز زیادہ `مآنگ` [درست] `user` تضاد کو سامنے لائیں اور
- B) `recommendations` کے لیے الگ الگ `scenarios` دونوں
- C) `preference` سب سے `حال` میں بیان کی گئی
- D) `balanced portfolio` تضاد کو حل کیے بغیر

مانگنا کی واحد clarification برا راست متضاد ہوں، تو تضاد سامنے لانا اور user کی preferences کیوں: جب A low risk کرنا اور Returns maximize کے اصل ارادہ سے ہم آہنگ ہو۔ user recommendation طریقہ کے بنیادی طور پر ناقابل مطابقت ادا ف میں جن کے لیے انسانی فیصلہ درکار ہے tolerance

## سوال 64

jazz کے "مجھے User کرتے ہیں playlist preferences refine میں conversation turns کئی Users: صورتحال "پسند ہیں؟ genres پوچھتا ہے "آپ کو کون سے Claude، بعد messages پسند ہے" کے دو

سب سے زیادہ ممکنہ وجہ کیا ہے؟

- A) Claude کو conversation memory کے لیے vector database connection برقرار رکھنے کے درکار ہے
- B) Model کی context window exceed ہو گئی ہے
- C) Claude API کو session\_id parameter کے درکار ہے
- D) شامل نہیں کر رہی ہے [درست] messages میں بچھلے messages array application آپ کی

request کے stateless API call ہیں — server-side memory کے پاس Claude: کیوں D کا کوئی علم turns کے پاس بچھلے Claude، شامل کیے بغیر conversation history میں مکمل messages array کا حصہ نہیں ہیں؛ دو architecture کے Claude (C) session\_id اور (A) Vector databases ہیں ہوتا ناممکن (B) context window overflow کے لیے exchange کے messages

## سوال 65

History تک پہنچ گئی ہے conversation 78,000 tokens، بعد cooking session صورتحال: 40 منٹ کے شامل ہیں آپ کو اسم معلومات discussion اور عمومی، allergies, recipe scaling, clarified cooking terms، کم کرنے ہیں tokens محفوظ رکھتے ہوئے

کے درمیان بہترین توازن رکھتا ہے؟ token reduction اور approach preservation کونسا

- A) خلاصہ کریں conversation history پوری
- B) رکھیں tokens صرف سب سے حالیہ 20,000
- C) خلاصہ کریں، اور discussion نکالیں، عمومی (allergies, quantities, preferences) structured data اسم رکھیں [درست] verbatim کو exchanges حالیہ
- D) کریں retrieve کے ذریعہ متعلقہ حصہ semantic search کریں اور conversation externally store مکمل

Allergies معلومات محفوظ رکھتی ہے valuable پر سب سے زیادہ cost سب سے کم Hybrid approach: کیوں C (summarization) ہوتا ہے میں compact structured block ایک critical facts جیسے recipe quantities اور exchanges ہوتی ہے، اور حالیہ discussion summarize عمومی، (سہ بچاتے ہوئے precision loss کے دوران conversational coherence کے لیے verbatim میں Options A اور B dietary information اسم کے لیے ضرورت سے زیادہ پیچیدہ ہے cooking session ایک D ہیں؛

## سوال 66

ka preferences اور topics پر assistant کے conversations میں reports کرتے ہیں کہ طویل Users: صورتحال رکھتی ہے message pairs صرف آخری 25 implementation حساب کھو دیتا ہے آپ کی موجود

کیا ہے؟ solution سب سے مؤثر

- A) Hybrid approach: messages پرانے حالیہ messages کا خلاصہ کرتے ہوئے حالیہ messages پرانے
- B) vector similarity search پر conversation history مکمل
- C) Window 50 message pairs تک بڑھائیں
- D) آگے جوڑیں running summary کا خلاصہ کریں اور dropped messages میں turn

A کیوں: Hybrid approach کے دونوں پہلوؤں کو حل کرتی ہے exact recent context کی (کے لیے) (conversational coherence) برقرار compressed representation کی preferences جبکہ (کے لیے) (C) بڑھانا Window رکھتی ہے miss کو context میں (B) Vector search صرف اسی مسئلہ کو ملتوی کرتا ہے (C) بڑھانا Window رکھتی ہے (D) semantically سے current query کر سکتی ہے جو

## سوال 67

بڑھ جاتی latency سے زیادہ ہوتے ہیں تو 50 turns conversations reports کرتے ہیں کہ جب Users: صورتحال بھی costs اور

بنیادی وجہ کیا ہے؟

- A) شامل ہوتی ہے conversation history کے ساتھ پوری API request
- B) Model gradually responses generate کرتا ہے
- C) History سے جو جاتا ہے database operations کے ساتھ
- D) Model بناتا ہے internal user profile کی ضرورت والا processing زیادہ

A کیوں: Claude کی API پر stateless مکمل طور پر request کو messages array میں پوری request بڑھتی ہے، conversation history شامل کرنی ہوتی ہے جیسے جیسے conversation history کے درمیان کوئی Model calls دونوں بڑھاتا ہے cost اور directly processing latency ل جاتی ہے، جو internal state (D غلط ہے)

## سوال 68

تک بڑھ گئی ہے جب conversation history 85,000 tokens، بعد weekly sessions: صورتحال: تین مہینوں کے discussions پچھلی assistant کے بارے میں کیا نتیجہ اخذ کیا تھا؟، تو theme کے isolation پوچھتا ہے "م نہ user کرنے کے بجائے عام جوابات دیتا ہے reference

کیا ہے؟ approach سب سے مؤثر

- A) Rolling window truncation
- B) Key conclusions capture کے ہوئے progressive summarization
- C) Relevant exchanges retrieve کے لیے (درست) semantic embeddings کرنے کے لیے
- D) Discussion conclusions mark کے لیے structured XML tags کرنے کے لیے

scale کو discussion □□ جو تین مہینوں کی approach واحد semantic search پر conversation history کیوں C □□ Rolling window کر سکتی □□□□ specific relevant exchanges surface پر demand کر سکتی □□ جبکہ truncation (A) history □□ Progressive summarization (B) discussions کا بیشتر حصہ ضائع کر دے گی □□ history (A) truncation ابstractions میں compress □□ کرتی □□ □□ users کھو دیتی □□ جن کا بار □□ میں specific conclusions ، کرتی □□ □□ compress میں abstractions بوجھ □□ ہیں □□

## سوال 69

کرتا ہے، system prompt guidelines میں 10-15 Claude، دوران QA testing: صورتحال  
 اندر 1000 token limits ابھی Conversation آجائی 1000 deviation میں responses لیکن بعد 1000

کیا ؟ solution بہترین

- A) Behavioral guidelines میں منتقل کریں □ user message کو پلا □
- B) 20 turns conversation □ شروع کریں □ بعد نئی
- C) Conversation breakpoints پر guidelines reinforce □ وال □ user-role messages insert [درست]
- D) Non-compliant responses کو regenerate □ لپ □ post-response validation □ استعمال کریں □

history کا براہ راست مقابلہ کرتا ہے Behavioral reminders کا periodic injection instruction drift کو regular intervals پر constraints re-establish کرتا ہے Guidelines کو user کو پر Accumulate message کو preventive (D) corrective Post-response validation کم کرتا ہے authority ان کا (A) میں منتقل کرنا شامل کرتی ہے significant latency اور preventive

## سوال 70

□□ teaching methodology اور adaptation rules □□ جو AI tutor 2,800 token-system prompt میں **صورتحال:** آپ کو define 12 □□□ □□□ assistant proficiency levels □□□ کر دیتا □□، بعد 12 turns کرتا □□□

کیا fix سب سے مؤثر

- A) 5–4 turns میں inject کریں
- B) Verbose rules کو proficiency-level adaptation demonstrate کرنے والے few-shot examples سے replace کریں [درست]
- C) Critical rules کو system prompt میں رکھیں
- D) Responses evaluate کریں اور اگر difficulty level match نہ ہو تو regenerate کریں

**B کیوں:** Declarative rules 2,800 والا token system prompt drift کیونکہ abstract rules vulnerable لی concrete few-shot examples کو Verbose rules کا تقاضا کرتے ہیں reasoning سے model میں turn ر clear کرنا لی match کو model، کریں demonstrate proficiency-level adaptation correct کرنا جو replace ہوتا ہے reliably سے زیادہ abstract instructions میں، turns دیتا ہے —، کئی behavioral patterns

## سوال 71

clarifying کرنا، اور reasoning explain برقرار رکھنا، اپنی enthusiastic tone کو assistant **صورتحال**: آپ کے □  
□ ہونی چاہئیں؟ □ define □ اس behavioral guidelines □ یوں □ □ questions



## سوال 74

Assistant 4+ clarifying requests میں "جیس" venue book اکثر "پارٹی" لی Users: صورتحال  
abandonment % پوچھتا ، جس سے 35 questions

کرتا ؟ improve کو بہترین طریقہ سے approach trade-off کونسا

- A) Hidden defaults کے ساتھ آگے بڑھیں
- B) میں پوچھیں compound message ایک clarifying questions تمام
- C) Assumptions explicitly بیان کریں اور [درست] corrections بڑھیں
- D) Structured intake form استعمال کریں

دیتا جبکہ غلط response کو فوری، مفید user بیان کرنا اور آگے بڑھنا Assumptions explicitly: کیوں C  
کو نہیں بتاتا کیا (A) user Hidden defaults کرنے کی صلاحیت برقرار رکھتا correct کو assumptions  
Structured کا تقاضا کرتی upfront effort سے user پھر بھی (B) Compound question list کیا گیا assume  
form (D) کی بجائے زیادہ شامل کرتا friction کم

## سوال 75

turns rules follow استعمال کرتا ابتدائی assistant contractor-persona system prompt صورتحال: آپ کا  
Conversational length 2,500 tokens صرف دیتا assistant generic advice تک 7 turn کرتے ہیں، لیکن

سب سے زیادہ ممکنہ وجہ کیا ہے؟

- A) System prompts کے لیے initial behavior establish صرف
- B) Turns accumulate کے ساتھ model کی attention ہوتی ہے
- C) Accumulated assistant responses system prompt اثر کو dilute [درست] ہیں
- D) System prompt صرف ایک بار بھیجا جاتا ہے

System prompt جمع ہوتے ہیں assistant responses میں conversation history کیوں: جیس جیس C  
behavioral constraints کو reflect کرنے والے assistant-generated content بڑھتے ہوئے proportion کا text کرنے والے  
بجائے اپنے پائل system prompt instructions پر بھی token lengths چھوٹے Model کم ہوتا جاتا ہے relative  
outputs کرتا compound کو drift، کرتا follow کو زیادہ patterns کے

## سوال 76

کئی Assistant "میں مدد کر سکتے ہیں؟" report کرتے ہیں جیس "کیا آپ requests میں Users: صورتحال  
abandonment % جس سے 40، (کیا؟ deadline؟ کیا مدد؟ report؟ کون سی) کرتا respond سوالات پوچھ کر  
ہوتا

کیا solution بہترین

- A) Reasonable assumptions کی پیشکش کریں [درست] adjustments بیان کریں، اور explicitly کریں، انہیں
- B) Respond کے ساتھ smaller model کرنے سے پائل
- C) Assumptions کریں predefined interpretations بیان کیے بغیر
- D) Assistant تک محدود کریں clarifying question میں ایک turn کو



رکھتے ہیں اور in control کو user کو informed کے ساتھ آگے بڑھنا Reasonable stated assumptions: کیوں A کرتی ہے confuse کو users (C) Silent predefined interpretations کو مکمل طور پر ختم کرتا ہے back-and-forth کی back-and-forth turns بھی (D) One-question limit ہے، match ان کے ارادے سے response میں جب latency اور infrastructure مسئلہ حل کے بغیر core UX (B) Smaller classification model ضرورت ہے شامل کرتا ہے complexity

## عملی مشقیں

### Exercise 1: Multi-tool Agent with Escalation Logic

Goal: tool integration, structured errors, اور escalation کے ساتھ agent loop بنائیں

### Exercise 2: Configuring Claude Code for Team Development

Goal: CLAUDE.md, custom commands, path-specific rules, اور MCP servers configure کریں

### Exercise 3: Structured Data Extraction Pipeline

Goal: JSON schema, validation/retry loops, اور Message Batches API کے ساتھ extraction pipeline بنائیں

### Exercise 4: Designing and Debugging a Multi-agent Research Pipeline

Goal: subagent orchestration, explicit context passing, error propagation, اور source tracking implement کریں

## Appendix: Technologies and Concepts

| Technology       | Key aspects                                                                                                            |
|------------------|------------------------------------------------------------------------------------------------------------------------|
| Claude Agent SDK | agent loops, <code>stop_reason</code> , hooks, <code>Task</code> , <code>allowedTools</code>                           |
| MCP              | servers, tools, resources, <code>isError</code> , <code>.mcp.json</code>                                               |
| Claude Code      | CLAUDE.md, <code>.claude/rules/</code> , <code>.claude/commands/</code> , <code>.claude/skills/</code> , planning mode |
| Claude Code CLI  | <code>-p</code> , <code>--output-format json</code> , <code>--json-schema</code>                                       |
| Claude API       | <code>tool_use</code> , <code>tool_choice</code> , <code>stop_reason</code> , <code>max_tokens</code>                  |

|                               |                                                     |
|-------------------------------|-----------------------------------------------------|
| <b>Message Batches API</b>    | 50% savings, 24-hour window, <code>custom_id</code> |
| <b>JSON Schema</b>            | required/optional, nullable, enum values            |
| <b>Few-shot prompting</b>     | ambiguous scenarios ❌ ❌ examples                    |
| <b>Prompt chaining</b>        | sequential decomposition                            |
| <b>Context window</b>         | token budget, lost-in-the-middle                    |
| <b>Confidence calibration</b> | field-level scoring, stratified sampling            |

## Out-of-Scope Topics

❌: موضوعات امتحان میں شامل نہیں ہیں

- Claude models کی fine-tuning
- Authentication, billing, یا account management
- implementation کی تفصیلی programming languages مخصوص
- hosting/infrastructure کی MCP servers
- Claude کی internal architecture یا model weights
- Constitutional AI, RLHF, یا safety training
- Embeddings یا vector databases کی implementation details
- Computer use / browser automation
- Vision / image analysis
- Streaming API یا SSE
- Rate limiting اور detailed API cost calculations
- OAuth اور API key rotation details
- Cloud-provider-specific configs
- Performance benchmarks
- Prompt caching implementation details
- Token counting algorithms

## Preparation Recommendations

1. بنائیں agent ❌ ساتھ ایک Claude Agent SDK
2. کریں configure پر real project کو Claude Code
3. کریں test اور MCP tools design
4. بنائیں Data extraction pipeline
5. کریں Prompt engineering practice
6. سیکھیں Context management patterns

7. Escalation اور human-in-the-loop workflows سمجھیں

8. Practice exam حل کریں